

Reto: Horno fusor de aluminio

Modelado y control de temperatura en hornos de fundición de aluminio mediante control clásico, moderno y predictores basados en redes neuronales

Sara Garza Reyna - A01612743

Ana Paulina Cisneros Negrete - A01567107

María José Zamora Gómez - A01704264

Santiago Castellanos Saavedra - A01705501

Análisis numérico para la optimización no-lineal

Dr. Leonardo Ledesma Domínguez

Dr. Fernando Gómez Salas

Grupo 601

Junio de 2026

Índice

Introducción
Objetivo
- Objetivo General
- Objetivos Específicos

Problemática industrial
“RONAL GROUP”
- Horno Fusor

Impacto del problema en la fabricación de rines de aluminio
Modelado matemático del sistema de control
- Metodología
- Modelo de control clásico

Análisis Exploratorio
Selección y justificación del modelo de Deep Learning
- Modelo preliminar
- Modelo preliminar con Deep Learning
- Redes Neuronales Convolucionales

Implementación del modelo de Deep Learning
- Ingeniería de variables
- Modelo: Arquitectura, Entrenamiento y Validación
  - Arquitectura
  - Entrenamiento
  - Validación
- Dinámica del sistema
- Implementación del modelo basado en datos en Simulink

Comparativa
- Comparativa de polos y ceros
- Comparativa por la respuesta a la misma entrada
- Comparativa del sistema

Discusión de resultados
Conclusión
Anexos y Referencias
- Anexos
- Referencias

Introducción

En la fabricación de rines de aluminio, el horno fusor es una de las etapas más importantes del proceso, ya que de él depende que el metal alcance y mantenga una temperatura adecuada antes de pasar a las siguientes fases de producción. En este tipo de sistema, la temperatura no cambia de forma inmediata, sino que aumenta o disminuye poco a poco debido al calor que debe absorber el aluminio y a las diferentes condiciones que se presentan durante la operación del horno.

Para la realización de este proyecto se analizó un horno fusor de aluminio tomando como referencia un modelo tipo Stack Tower Melter, utilizado para procesos de fundición de alta capacidad. El sistema trabaja alrededor de una temperatura de operación cercana a los 780 °C, el cual es un valor necesario para mantener el aluminio correctamente fundido y evitar problemas como la solidificación parcial, el sobrecalentamiento, el incremento en el consumo energético o variaciones térmicas que puedan afectar la calidad del material utilizado en la fabricación de rines. Además, el horno presenta características importantes para el modelado, como un retardo de calentamiento, una constante de tiempo elevada, inyección de gas y restricciones físicas en la acción de control.

Durante la operación del horno fusor pueden presentarse perturbaciones que modifican su comportamiento térmico, como cambios en la carga de aluminio, apertura del horno durante la recarga, variaciones en la temperatura ambiente, fallas en sensores, cambios en la entrada de gas o saturación de los inyectores. Estas condiciones hacen que el control de temperatura sea un problema relevante, ya que una mala sintonización del controlador puede generar sobreimpulsos, errores en estado estable, tiempos largos de estabilización o variaciones no deseadas en la temperatura del aluminio.

Por esta razón, el sistema no se analiza únicamente desde una perspectiva ideal, sino mediante dos enfoques complementarios. El primero corresponde al modelado y control clásico, donde se representa la dinámica térmica del horno mediante una función de transferencia, se consideran elementos como el retardo y se evalúa la respuesta del sistema ante diferentes condiciones. El segundo enfoque está basado en datos mediante redes neuronales, utilizando información del proceso para aproximar el comportamiento de la temperatura y analizar si este tipo de modelo puede capturar la dinámica real del horno fusor.

De esta manera, el proyecto busca comparar modelos físicos y modelos basados en datos para describir la respuesta térmica del horno fusor, evaluando cuál representa mejor el comportamiento del sistema y contribuye a una operación más estable y eficiente en el proceso de fundición de aluminio.

Objetivo

Objetivo General

Desarrollar modelos de la dinámica térmica en hornos de fundición de aluminio, integrando predictores basados en redes neuronales y enfoques de control clásico o moderno, con el fin de analizar su utilidad en la representación del sistema y apoyar la sintonización inicial de controladores de temperatura.

Objetivos Específicos

- Identificar las variables relevantes del sistema térmico en hornos fusores y de sostenimiento.
- Realizar análisis exploratorio de datos para comprender el comportamiento del sistema.
- Desarrollar un predictor basado en redes neuronales para aproximar la dinámica térmica.
- Construir un modelo del sistema mediante control clásico (Laplace) o moderno (espacio de estados).
- Diseñar un controlador de temperatura basado en el modelo obtenido.
- Evaluar el desempeño de los modelos mediante simulación.
- Comparar los enfoques físicos y basados en datos.

Problemática industrial

En la operación de un horno fusor de aluminio, el control de temperatura es un reto importante porque el sistema depende de diferentes sensores, actuadores y condiciones de trabajo. Aunque los sensores permiten medir variables como temperatura, flujo de gas, carga de aluminio y consumo energético, esto no asegura por sí solo que el proceso sea estable. Si el controlador no está bien ajustado o si existen perturbaciones, pueden aparecer sobreimpulsos, errores en estado estable o tiempos largos de estabilización.

Además, en una planta industrial también influye el factor humano. El hornero suele tomar decisiones con base en su experiencia, pero cada operador o turno puede trabajar de manera diferente. Esto se vuelve más evidente cuando hay rotación de personal, ya que no todos interpretan igual el comportamiento del horno ni responden de la misma manera ante cambios de carga, variaciones en la temperatura o fallas en el sistema. Es por eso que contar con modelos de control y predictores basados en datos ayuda a reducir la dependencia del criterio individual y permite buscar una operación más estable y eficiente.

Por lo tanto, la problemática no solo está en mantener el aluminio a una temperatura adecuada, sino en lograr que el proceso sea repetible y confiable sin importar el turno, el operador o las perturbaciones presentes. Un modelo bien desarrollado puede servir como apoyo para entender mejor la dinámica del horno, anticipar cambios en la temperatura y facilitar la toma de decisiones dentro del proceso de fundición.

“RONAL GROUP”

Ronal Group es una empresa fundada en 1969 en Walldorf, Alemania, y con sede actual en Härkingen, Suiza. Cuenta con dos áreas de negocio distintas que trabajan con aleaciones de aluminio: la primera y con la que el equipo trabajará el reto es la división Ronal Wheels, que es uno de los principales fabricantes de rines para vehículos comerciales y de turismo. Asimismo, la otra división, Ronal Bathrooms fabrica productos de aluminio en los sectores de espacios de baño y bienestar.

Además de su sede en Suiza, Ronal tiene 18 plantas de producción y oficinas administrativas en 14 países: Suiza, Alemania, Francia, Italia, México, Polonia, Portugal, España, Estados Unidos, Reino Unido, Taiwan, República Checa, Rumania y Sudáfrica.

Ronal Group tiene alrededor de 7000 empleados en todo el mundo, y durante el año 2024 y 2025 facturó 1.36 billones de euros con un 58.7% de capital propio y 66.4 millones de euros de inversiones. La capacidad de producción de Ronal Group es muy extensa, pues en la planta de producción en la ciudad de Querétaro se pueden producir hasta 3.4 millones de rines al año. Esta planta cuenta con múltiples estaciones de pintura, pulido, control de calidad, sellado y dos tipos de hornos: fusor y de sostenimiento.

Horno Fusor

Existen dos sistemas industriales principales en la planta de San Juan del Rio de RONAL Group:

- Horno fusor: Los hornos fusores pueden funcionar con gas natural, electricidad, inducción o combustibles líquidos, dependiendo del tamaño de producción, costo energético y calidad requerida. Con un horno de este tipo, el aluminio puro se funde cerca de los 660 °C, aunque en la industria normalmente se trabaja a temperaturas un poco mayores para mantenerlo líquido y facilitar su manejo.

  .

- Horno de sostenimiento: Los hornos de sostenimiento no están pensado principalmente para fundir grandes cantidades de aluminio desde sólido, sino para mantener el aluminio ya fundido a una temperatura estable. El horno

utiliza resistencias eléctricas para proporcionar una mayor estabilidad térmica, permitiendo mantener el aluminio fundido a una temperatura constante y adecuada durante el proceso de producción.

En este proyecto se trabaja con un horno fusor, cuya principal función es fundir el aluminio (puro o en aleación) a la temperatura adecuada para ser moldeado en la forma de los rines. Como referencia para hacer el modelo preliminar, se utilizó el horno Stack Tower Melter de la empresa Lindberg/MPH, el cual cuenta con las siguientes características:

a) Capacidad de 6800 kg por hora
b) Temperatura de operación: 780°
c) Tiempo de retardo para calentamiento: 10 minutos (600 segundos)
d) Tiempo total de calentamiento hasta la constante de tiempo (τ): 180 minutos (10800 segundos)
e) Consumo de energía: 2674 kg/kJ



Imagen 3: Horno Stack Tower Melter

El horno fusor utiliza inyección de gas para cumplir con sus funciones, la cual también se incluyó en el modelado.

Impacto del problema en la fabricación de rines de aluminio

El impacto de esta problemática se refleja en la fabricación de rines de aluminio, ya que el horno fusor es una de las primeras etapas del proceso de producción. Si la temperatura del aluminio no se mantiene dentro de un rango adecuado, pueden presentarse variaciones en sus propiedades y en su comportamiento durante el proceso de fundición. Esto afecta las etapas de moldeo, solidificación y acabado, provocando que el rin no tenga las condiciones necesarias de calidad.

Cuando el aluminio no llega en condiciones térmicas correctas, aumenta la posibilidad de generar piezas con defectos, variaciones dimensionales o problemas en la superficie del rin. Esto puede significar que algunas piezas sean rechazadas, lo cual afecta tanto la calidad del producto final como el tiempo de producción y el aprovechamiento del material.

Además, una mala regulación de temperatura puede generar pérdidas económicas importantes. Si el horno tarda demasiado en estabilizarse, consume más energía y retrasa la producción; y si se producen rines defectuosos, se pierde material, tiempo y capacidad productiva. Incluso, si un producto con defectos llegara al cliente, también podría verse afectada la reputación de RONAL, ya que la confianza de los clientes depende de recibir rines seguros, consistentes y de buena calidad, haciendo que disminuyan sus ventas por productos de mala calidad. Por esta razón, el control de temperatura en hornos fusores es un factor clave para mantener una producción constante, reducir desperdicios y asegurar que los rines fabricados cumplan con los estándares requeridos.

Modelado matemático del sistema de control

Metodología

Se analizan distintas estrategias de control, como los controladores P, PI, PD y PID, con el propósito de comparar su comportamiento durante el proceso de calentamiento y fusión del aluminio.

De acuerdo con el artículo de 2024 de Grant Maloy Smith publicado en Dewesoft, un controlador PID es:

> Controlador P: Responde directamente al error de temperatura, aumentando o reduciendo la potencia de calentamiento en función de la diferencia entre la temperatura medida y la temperatura de referencia. Sin embargo, puede presentar error en estado estacionario.
>
> Controlador PI: Este controlador incluye una acción integral, la cual ayuda a corregir el error acumulado con el tiempo. El controlador PI ayuda a que el horno no se quede por debajo de la temperatura deseada. Esto es importante, ya que una temperatura insuficiente puede provocar que el aluminio no se funda correctamente o que el proceso tarde más tiempo.
>
> Controlador PD: Este tipo de controlador incluye la acción derivativa, la cual ayuda a anticipar cambios en la temperatura y puede reducir oscilaciones o sobre impulsos durante el calentamiento. Sin embargo, no elimina por completo el error en estado estacionario, ya que no cuenta con acción integral.
>
> Controlador PID: Este controlador combina la acción proporcional, derivativa e integral. Esto permite obtener una respuesta más completa, ya que corrige el error actual, elimina el error acumulado y suaviza los cambios bruscos en la temperatura del horno al mezclar los 3 elementos.

La variable objetivo del sistema corresponde a la temperatura del horno, ya que es el parámetro principal que se desea regular durante el proceso de fusión. La variable manipulada es la potencia de calentamiento suministrada al horno, la cual puede modificarse mediante la señal de control generada por el controlador.

$$Variable\ controlada\colon\ T(t)$$

$$Variable\ manipulada\colon\ u(t)$$

El controlador PID trabaja sobre el error $e(t) = r(t) - y(t)$ y genera la salida de variable manipulada $u(t)$ de la siguiente manera:

$$C(s) = K_p(1 + \frac{1}{T_i s} + T_d s)$$

Donde:

K_p representa la ganancia proporcional sobre el controlador

$\frac{1}{T_i s}$ indica el inverso del tiempo integral del sistema

$T_d s$ representa el tiempo derivativo del sistema

Modelo de control clásico

El modelado de control clásico se basa en la función de transferencia que se obtiene a partir de ecuaciones diferenciales, la cual corresponde a la planta del sistema de control. La ecuación inicial de primer orden utilizada en el sistema es:

$$\tau \frac{dy(t)}{dt} + y(t) = K * u(t)$$

Donde:

K es la ganancia final del sistema, o en el caso de un horno, el setpoint

y(t) es la salida el sistema

u(t) es la entrada o perturbación

τ es la constante de tiempo, que indica la rapidez de la respuesta del sistema

La ecuación anterior dice que la tasa de cambio de la salida, ponderada por τ más la salida es proporcional a la entrada. Ahora, con el fin de hacer el problema más manejable, se aplica la transformada de Laplace a ambos lados de la igualdad con las condiciones iniciales $y(0) = 0$, lo cual resulta en la siguiente ecuación:

$\tau sY(s) + Y(s) = K * U(s)$, despejando a : $Y(s)(\tau s + 1) = K * U(s)$

Despejando la función de transferencia, que corresponde a $G(s) = \frac{Y(s)}{U(s)}$:

$G(s) = \frac{K}{\tau s+1}$

El polo del sistema se ubica en $s = -\frac{1}{\tau}$ en el semiplano izquierdo, lo que significa que el sistema es estable.

En sistemas reales, como en un horno de fusión existe un retardo puro L, que representa el tiempo que tarda la entrada en comenzar a afectar la salida. En el dominio del tiempo se agrega como:

$\tau\frac{dy(t)}{dt} + y(t) = K * u(t - L)$

Ahora, por el teorema de desplazamiento temporal de Laplace, que establece que retrasar una función en el tiempo por una constante positiva equivale en el dominio de la frecuencia a multiplicar la transformada de laplace por e^{-Ls}, haciendo que la función de transferencia en el dominio de la frecuencia sea:

$G(s) = \frac{Ke^{-Ls}}{\tau s+1}$

Sin embargo, como el término e^{-Ls} no es un término lineal y produce una serie infinita en s, el valor de la frecuencia. Se busca linealizar la función para que quede de la forma:

$e^{-Ls} \approx \frac{a_0+a_1 s}{b_0+b_1 s}$, haciendo coincidir los primeros términos de la expansión de Taylor de retardo y tomando $b_0 = 1$ como normalización y expandiendo por series:

$\frac{a_0+a_1 s}{b_0+b_1 s} \approx (a_0 + a_1 s)(1 - b_1 s + b_1^2 s_2 - \ldots)$

Igualando con los coeficientes de e^{-Ls}:

Término constante $a_0 = 1$

Término en s: $a_1 - a_0 b_1 = -L$, que se traduce en $a_1 - b_1 = -L$

La solución simétrica da: $a_1 = -\frac{L}{2}$ y $b_1 = \frac{L}{2}$, resultando en la función de transferencia:

$$e^{-Ls} \approx \frac{1 - \frac{L}{2}s}{1 + \frac{L}{2}s} \implies G(s) = \frac{K!\left(1 - \frac{L}{2}s\right)}{(\tau s + 1)!\left(1 + \frac{L}{2}s\right)}$$

El método de sintonización de controladores mediante el lugar geométrico de las raíces consiste en formar una función cuyos polos y ceros se encuentren en el semiplano izquierdo para así poder crear un sistema estable. Los ceros son las raíces del polinomio en el numerador y hacen que la función de transferencia sea igual a cero, mientras que los polos son las raíces del polinomio en el denominador y es donde los valores de la función de transferencia tiende al infinito.

Este método es de alta precisión y permite obtener directamente los valores deseados para la planta, aunque para ello se necesita obtener primero la función de transferencia del modelo.

Las variables que se manejan y modifican en el sistema para encontrar la simulación más adecuada incluyen la temperatura de setpoint del horno, la temperatura final (K), el tiempo de retardo del sistema (L), el tiempo total de calentamiento y la constante de tiempo τ, que corresponde al tiempo donde el sistema llega al 63.2% de la temperatura final.

En el modelo del horno fusor se considera un tiempo de retardo (L), el cual representa el tiempo que tarda el sistema en comenzar a reflejar un cambio de temperatura después de aplicar una entrada de calentamiento. Este retardo aparece en la función de transferencia como un término exponencial (e^{-Ls}). Sin embargo, este término no es una función racional, por lo que dificulta el análisis mediante herramientas clásicas de control, como el lugar geométrico de las raíces o el análisis de polos y ceros.

Para poder trabajar el retardo dentro del modelo clásico, se utiliza una aproximación de Padé de primer orden. Esta aproximación permite representar el término exponencial como una razón de polinomios, manteniendo una representación más sencilla para el análisis del sistema.

1. Definición de variables basadas en datos reales e investigados.

   Si se considera que se trata de un sistema de primer orden, es decir, no hay oscilaciones, la función de transferencia tiene la forma:

   $$G(s) = \frac{Ke^{-\theta s}}{\tau s+1}$$

   Sustituyendo los valores de la referencia consultada, tomaría la siguiente forma:

   $$G(s) = \frac{780e^{-600s}}{10800s + 1}$$

Para hacer una simulación más adecuada a lo que se observa en la vida real, se tomarán en cuenta algunas perturbaciones físicas del sistema, las cuales afectan directamente los tiempos y la temperatura. Asimismo, se busca saber si dichas perturbaciones vuelven inestable al sistema y en qué punto lo hacen. En el sistema manejado en el modelo de control del equipo se consideran las siguientes perturbaciones:

- Afectaciones a los sensores:
  - Fallas en los sensores o en el controlador que afecten a la señal. Pueden estar causadas por apagones, fallos en el cableado o componentes electrónicos del horno
  - Falta de mantenimiento o desgaste natural por la edad del equipo.

- Propias del sistema o el controlador:
  - El horno fusor trabaja también con inyección de gas, pero tiene una componente eléctrica que puede ser afectada por factores externos (apagones, cambios en la intensidad de corriente, etc.).
  - Perturbaciones causadas por una falla en los inyectores, afectando la entrada de gas.

- Externas al sistema:
  - Sobrecarga de material: El horno también cuenta con una capacidad limitada, por lo que sobrecargarlo podría retrasar la producción de

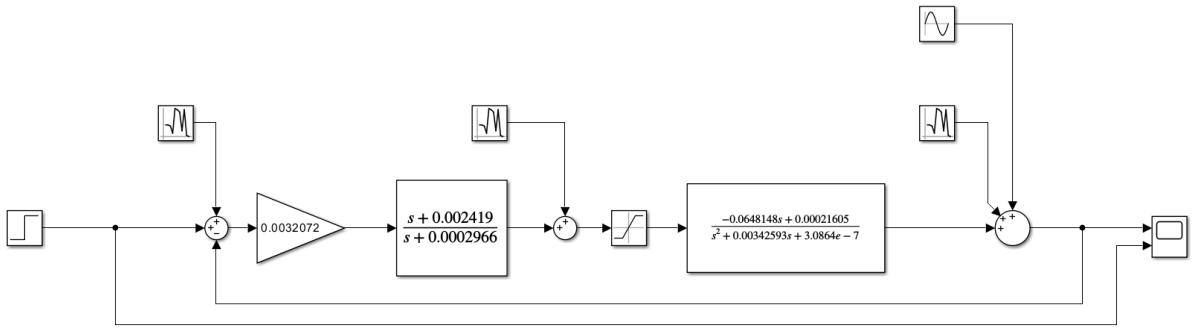
material, pero sobre todo causar cambios de temperatura bruscos al momento de ingresar la carga al horno.

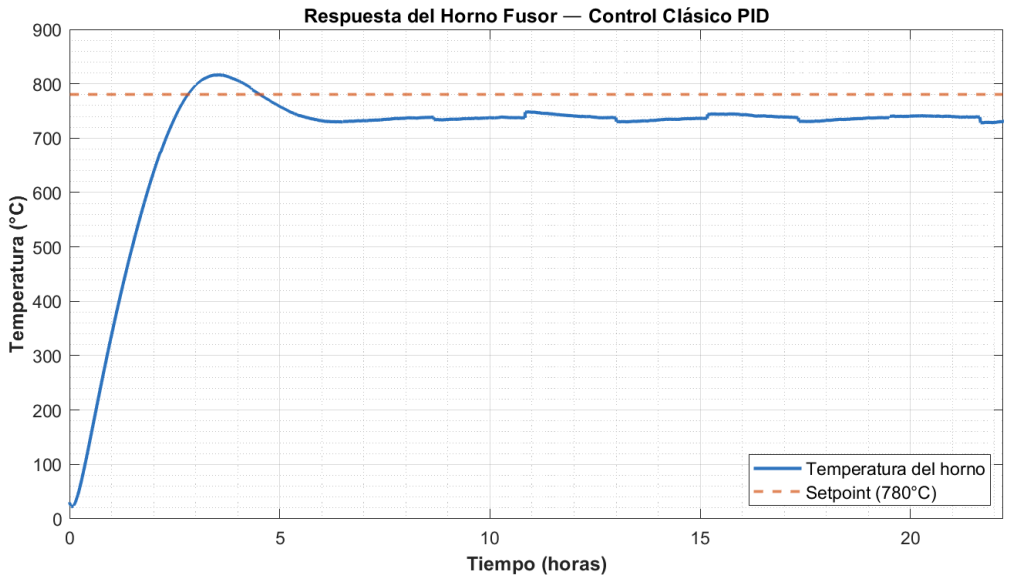
- Recarga de material: Cuando el material frío ingresa al horno y la puerta del mismo se abre, pueden producirse cambios en la temperatura y en la producción del material, por lo que se tomará en cuenta para minimizar los cambios.

Además, se toma en cuenta la temperatura externa. Una mayor temperatura en el ambiente afecta el comportamiento general de la planta y al proceso de fundición del aluminio.

Adicionalmente, también se contempla una “Saturación” que simula los inyectores de gas. Se limita esta cantidad a dos inyectores, con un uso mínimo en cero. Esto busca simular el ambiente más real posible.

Se obtiene como resultado lo siguiente:

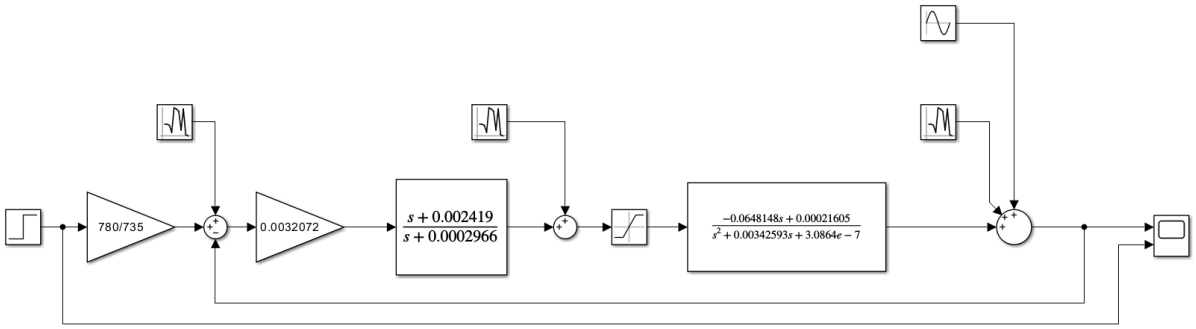


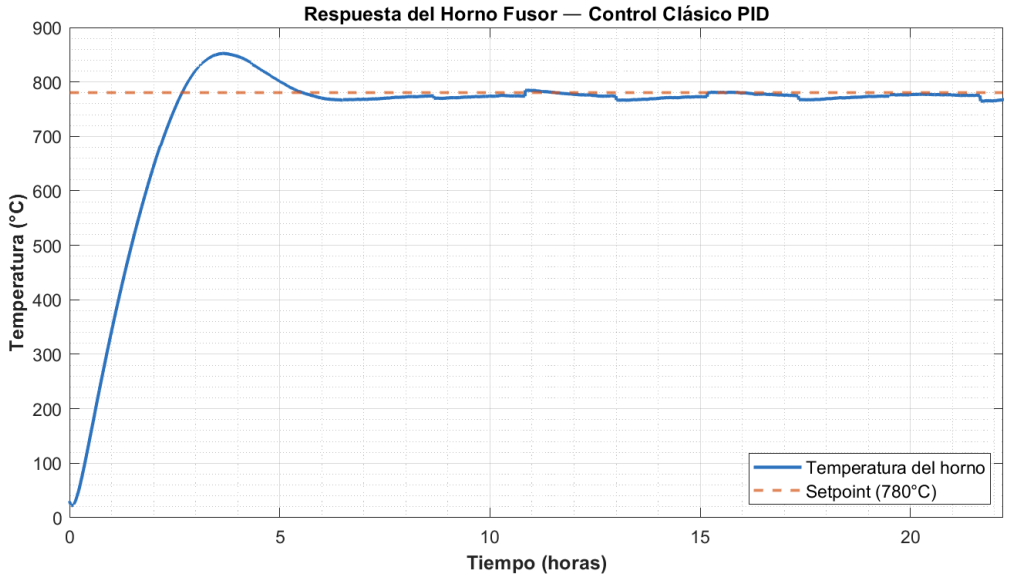


Se obtiene que la temperatura en estado estable es $T_{ss} = 735$. Esto representa un error en estado estable significativo, $e_{ss} = 45$.

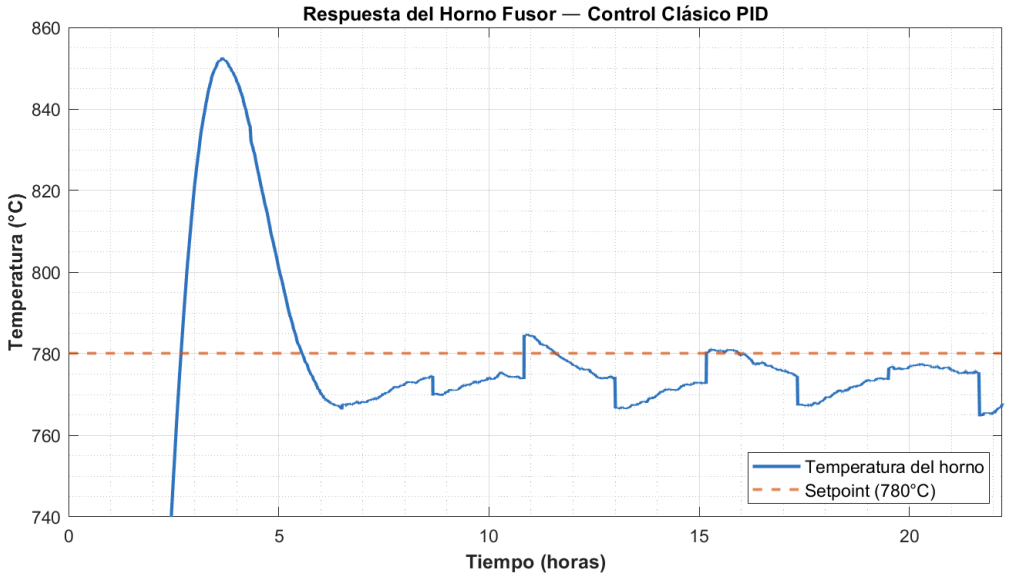
Pero al observarse un error en estado estable tan grave, es necesario agregar una ganancia que pueda corregirlo. Esta se calcula comparando la temperatura objetivo y la obtenida. Por lo que $K = 780/735 \approx 1.06$

Este método, conocido como sintonización de controladores por medio del Teorema del Valor Final, es muy simple y común en el control clásico. Se obtiene un nuevo sistema, con mejor comportamiento:





En este modelo, se pueden observar las pequeñas variaciones causadas por las perturbaciones y se interpretan como un modelado adecuado de la dinámica del sistema cercano al real. Estas diferencias quedan dentro del rango de $\pm 20^{\circ}$ permitido.

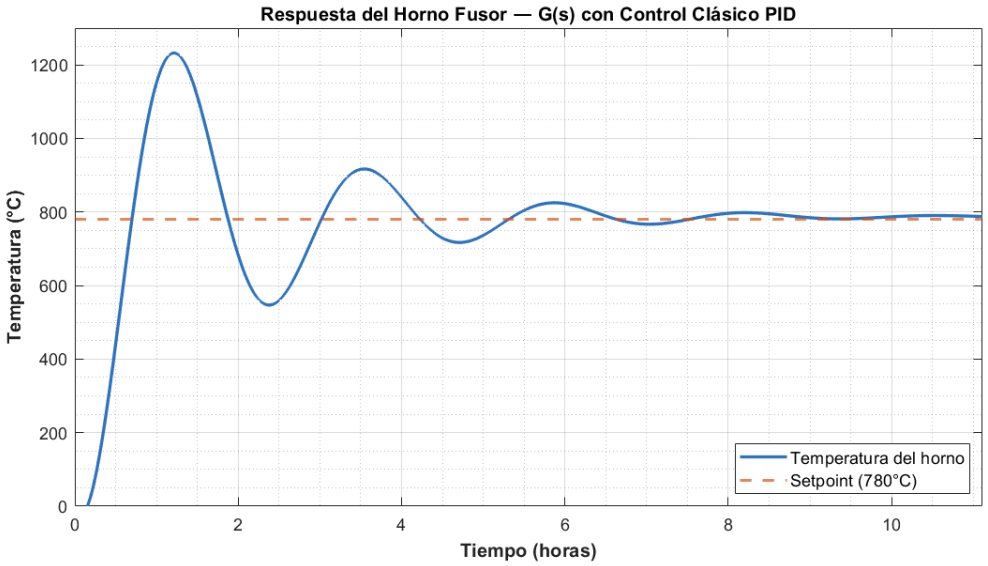


Obtener la función continua en lazo cerrado del sistema es sencillo, solo es cosa de reducir los bloques. Sin embargo en el diagrama hay dos bloques que, al no ser lineales no se pueden incluir. El primero es el de las perturbaciones, que al ser un valor aleatorio no se pueden incluir dentro de la función G(s) ni es necesario; pues el objetivo de obtener esta función es compararla con la del modelo basado en datos también sin perturbaciones. El segundo bloque que no se puede reducir es el de la saturación.

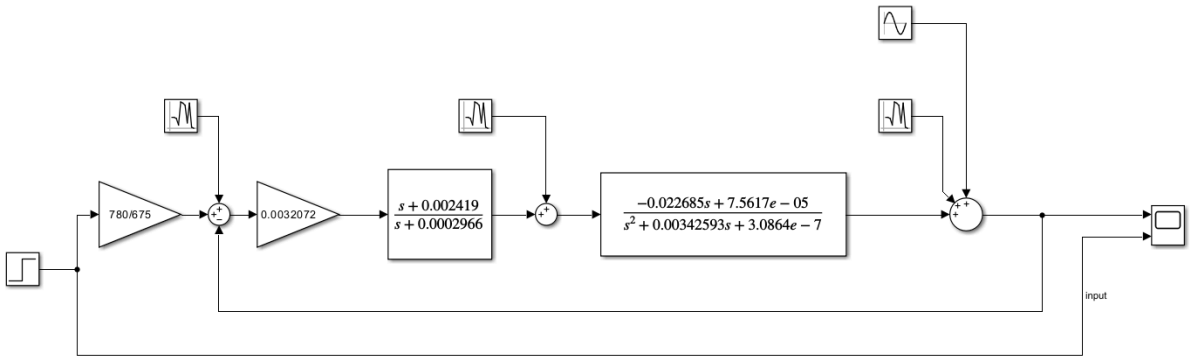
Sin considerar las perturbaciones ni la saturación, la función continua en lazo cerrado que describe a este sistema es la siguiente:

$$G_{cl}(s) = \frac{-0.0002341s^2 + 2.141 \times 10^{-7}s + 1.888 \times 10^{-9}}{s^3 + 0.003502s^2 + 1.526 \times 10^{-6}s + 1.87 \times 10^{-9}}$$

En la figura se muestra su comportamiento en respuesta a un step. Sin embargo, se observa el gran cambio que tiene el comportamiento del sistema.



Por lo que se toma la decisión de adaptar el bloque de la saturación a un bloque de ganancia equivalente ($K = 0.35$). El diagrama de bloques queda de la siguiente manera:



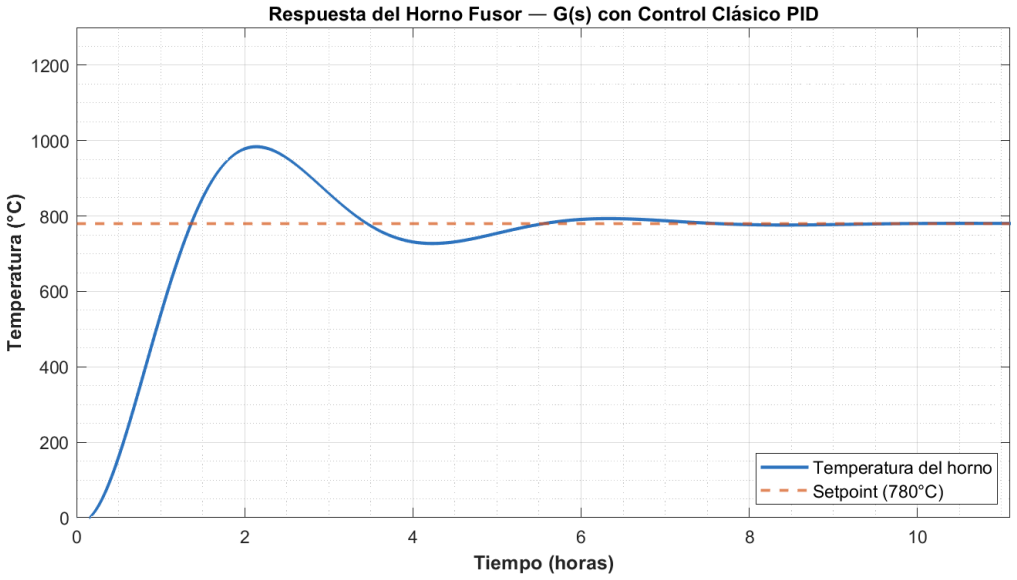
La función de transferencia en lazo cerrado de este sistema es, en su forma polinomial:

$$G_{closed}(s) = \frac{-8.407 \times 10^{-5} s^2 + 7.687 \times 10^{-8} s + 6.779 \times 10^{-10}}{s^3 + 0.00365 s^2 + 1.391 \times 10^{-6} s + 6.782 \times 10^{-10}}$$

O, en la forma de ceros-polos-ganancia (ZPK):

$$G_{closed}(s) = \frac{-8.4073 \times 10^{-5} (s - 0.003333)(s + 0.002419)}{(s + 0.003289)(s^2 + 0.0003603 s + 2.062 \times 10^{-7})}$$

Y la respuesta de esta función a un step sí replica el comportamiento del sistema que se trazó en bloques en Simulink.



Los polos del sistema en lazo cerrado son los siguientes:

Real, dominante: $p_1 = -0.0033$

Par complejo conjugado: $p_{2,3} = -0.0002 \pm 0.0004j$

Y los ceros:

$$z_1 = +0.0033$$

$$z_2 = -0.0024$$

Nótese que el cero en $z_1 = +0.0033$ indica comportamiento de fase no mínima (non-minimum phase). Es decir, limita qué tan agresivo puede ser el controlador.

El análisis de estado estable indica que:

$$K_{DC} = \lim_{s \to 0} G_{closed}(s) = 0.999579$$

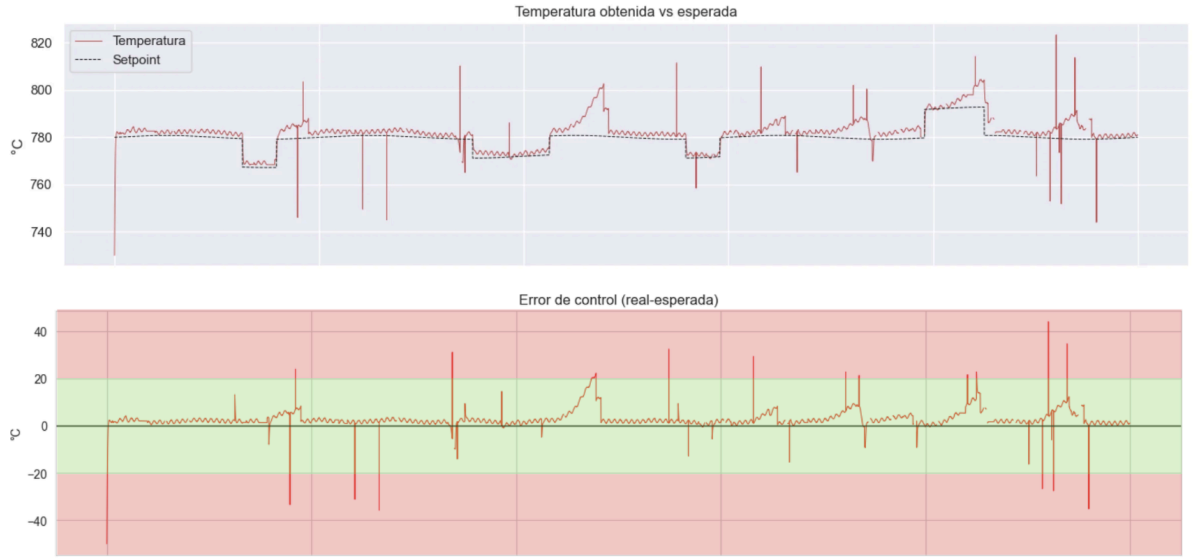
$$T_{ss} = 780 \cdot K_{DC} = 779.67°C$$

$$e_{ss} = 780 - T_{ss} = 0.33°C$$

Análisis Exploratorio

Previo a la elección de un modelo de Deep Learning que nos permitiera encontrar una aproximación de la función que describa al sistema de primer orden con retardo, fue esencial llevar a cabo un Análisis Exploratorio de los Datos que fueron proporcionados por Ronal Group. Para este paso, utilizamos un dataset con 21,600 muestras tomadas de un horno fusor, para las cuales se tienen medidas de flujo de aire, flujo y presión de gas, temperatura ambiente, carga de aluminio, consumo energético, temperatura de referencia, temperatura medida por el sensor; dos variables más fueron añadidas para enriquecer el análisis, siendo estas el error (sustrayendo la temperatura de referencia de la temperatura obtenida), y el turno (obtenido a partir de los tiempos en los que cada muestra fue tomada).

Como primer acercamiento, se graficaron las temperaturas reales contra las esperadas, al igual que los errores de control obteniendo lo siguiente:

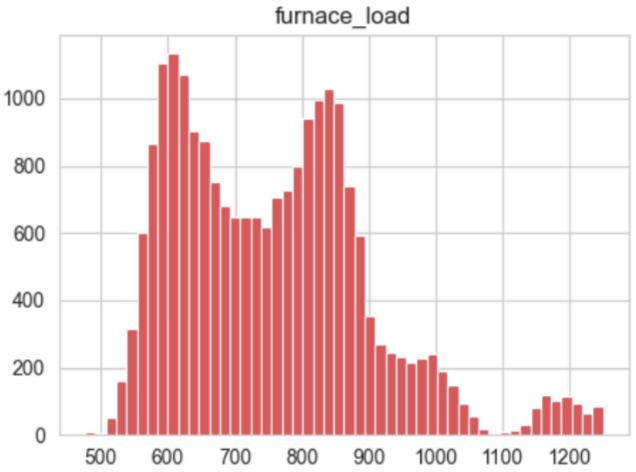


A partir de lo anterior, un primer hallazgo es que, en realidad, existe poca disparidad entre el setpoint y la temperatura percibida por el sensor, encontrando un error promedio de 2.77°C, sin embargo, llama la atención que hay picos muy elevados, llegándose a percibir errores de hasta +40°C y de -50°C. En términos generales, el horno presentó solo 366 registros fuera de rango, es decir, 1.7% de las muestras totales.

Asimismo, cuando el setpoint sube en escalón, la temperatura real sufre un sobreimpulso más gradual, y la temperatura tarda un poco en estabilizarse. A partir

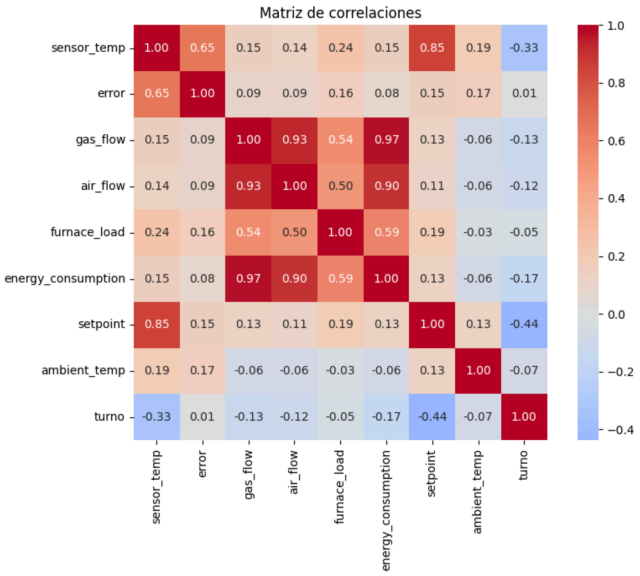
de esto, pareciera que existe un retardo cuando la temperatura debe subir abruptamente.

Posteriormente, se grafican las distribuciones de probabilidad de cada variable, encontrando algo interesante únicamente para una variable.

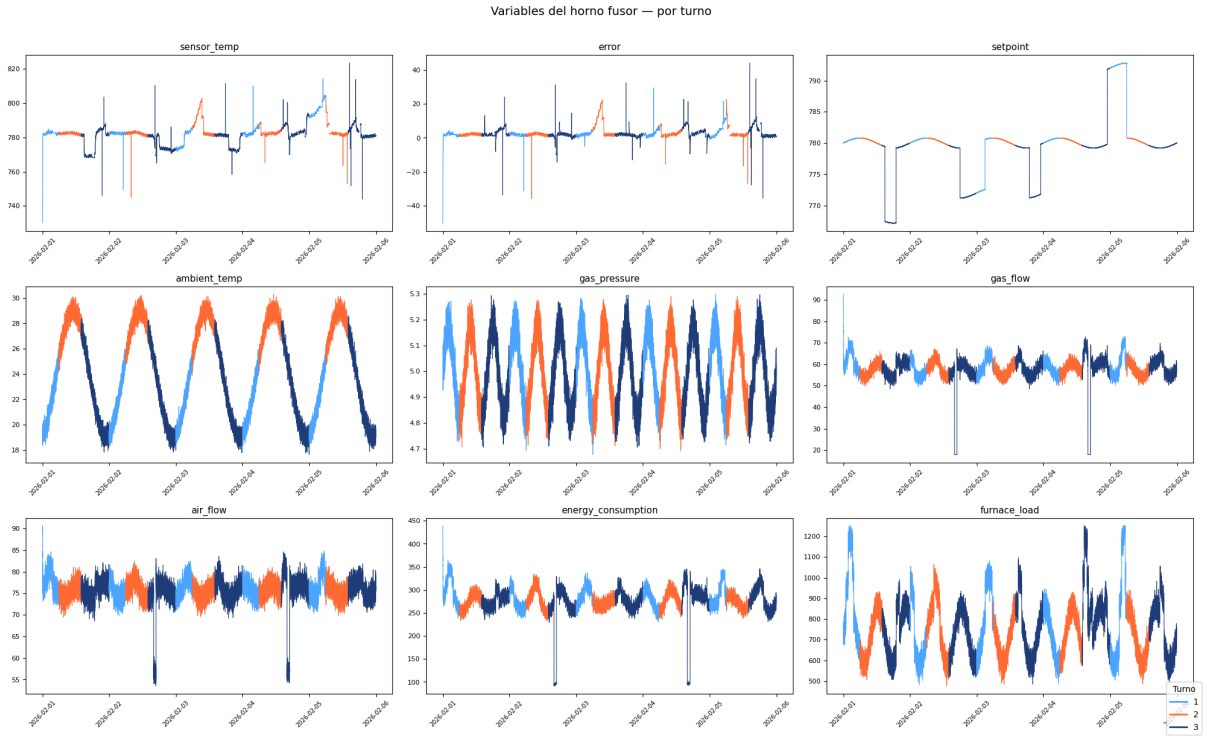


La variable ‘furnace_load’ que contiene la información de la carga de aluminio por muestra presenta una distribución que se asemeja a una bimodal. Pareciera que el horno opera con dos cargas distintas a lo largo de la jornada, tiene distribución bimodal. pareciera que el horno opera con dos cargas distintas a lo largo de la jornada.

A continuación, se presenta la matriz de correlaciones del dataset.



Una correlación interesante que se observa es la del turno. Se crea esta gráfica para visualizar de mejor manera la relación de esta variable (que se creó en base al uso estándar en méxico) con el resto de las variables:

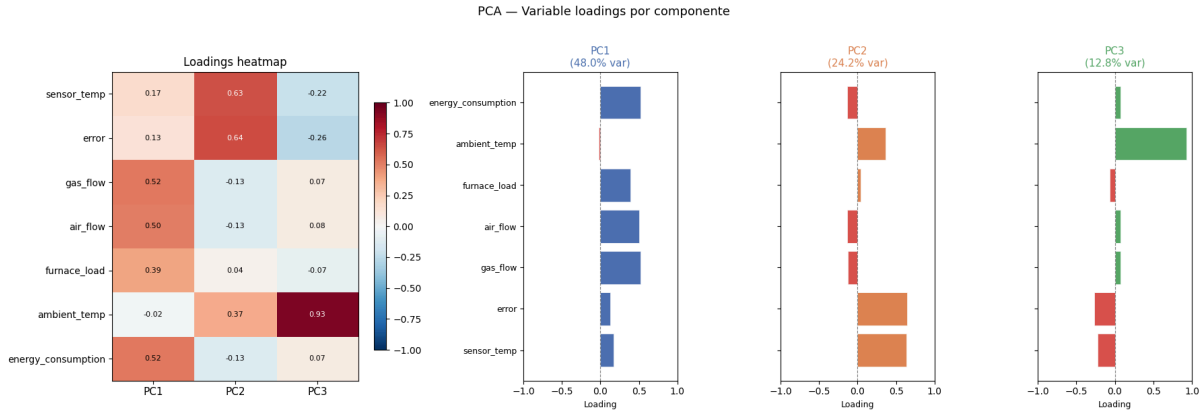


Esta imagen deja en claro la relación que existe entre el comportamiento del sistema con el turno, que, aparte de poderse atribuir al factor humano ó a la experiencia única de cada hornero que trabaja con el horno; deja en claro la fuerte relación de patrón que tienen los datos. En otras palabras, el valor actual de las variables está relacionado con su historial.

Otro hallazgo que sale de aquí es que el setpoint no es el mismo en todos los turnos, por lo que es esencial que el controlador aplicado tome estas fluctuaciones en consideración. Además, el error y la carga no presentaron ninguna correlación con el turno, lo cual nos habla de un buen control entre diferentes turnos.

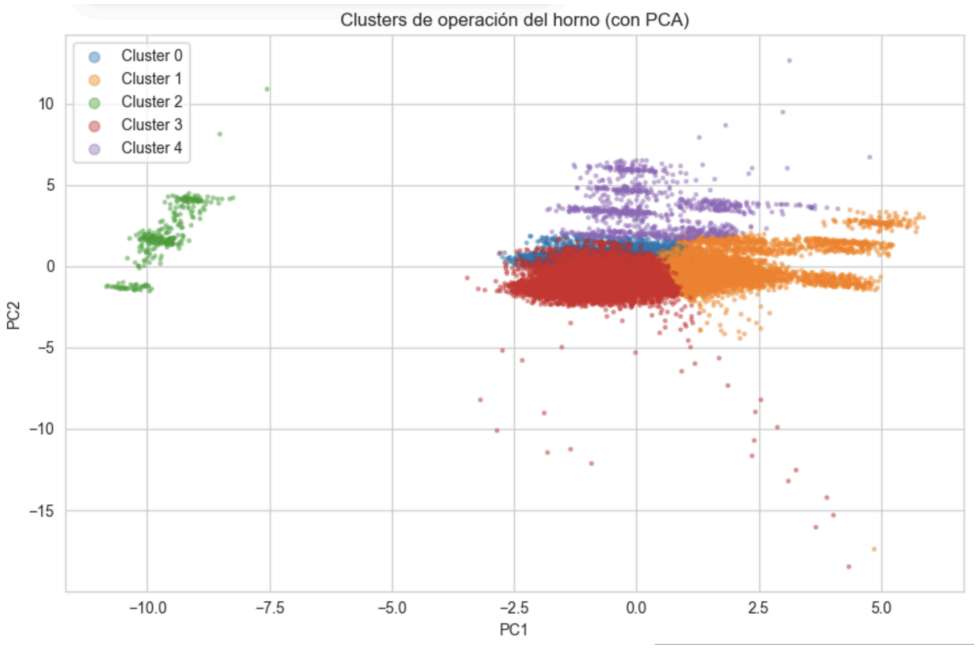
Con base en el anterior análisis, se optó por utilizar un algoritmo de clustering para observar si las muestras se agrupan de alguna manera, por lo que llevamos a cabo k-means, no sin antes llevar a cabo un Análisis por Componentes Principales (PCA), donde 3 componentes principales contuvieron ~85% de la varianza de los datos, y escalar los datos. Los clusters graficados se presentan a continuación, sin embargo, es importante mencionar que, los clusters se encuentran graficados en 2D, sin embargo, sí se utilizaron los 3 PCs.

Estos tres componentes principales tienen las siguientes características:



Interpretar correctamente esta información es útil pues posteriormente, tomando como eje X el PC1 y como eje Y el PC2, los registros se separaron en 5 clusters. Entender qué significa cada eje resulta valioso al momento de interpretar el espacio y por ende, los grupos que se forman en él.

En este caso, el primer componente principal se interpreta como energía utilizada y/o variables internas del horno. El segundo como los ajustes seleccionados ó bien, la relación con el hornero. Esto porque se interpreta que la temperatura ambiente es muestra del turno y el setpoint se define a discreción del hornero.



El perfil de los grupos, es decir, su promedio por grupo, se presenta a continuación.

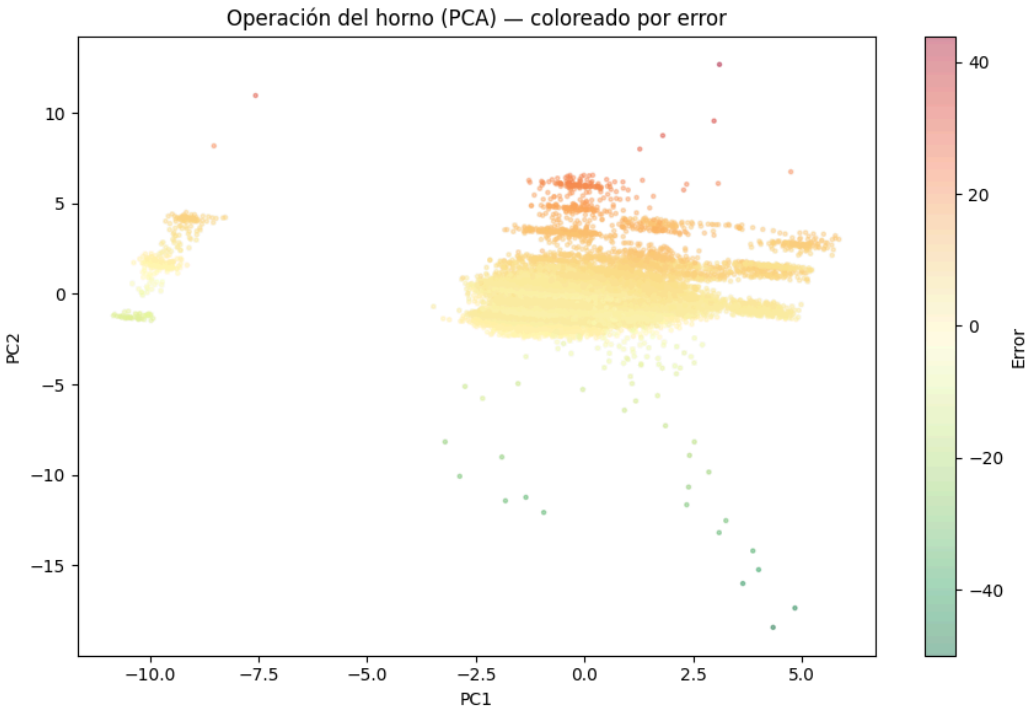
cluster	sensor_temp	error	gas_flow	air_flow	furnace_load	ambient_temp	energy_consumption
0	782.41	2.22	57.22	75.41	714.54	27.47	272.96
1	783.98	3.47	62.98	78.34	935.01	22.6	305.67
2	780.25	0.98	18.0	56.67	785.6	24.72	96.23
3	778.78	1.46	56.08	74.87	662.0	20.83	269.43
4	794.44	12.82	56.95	75.23	708.71	26.69	272.49

Los grupos 3, 0, 1 representan los momentos de operación estable con diferentes cargas: baja, media y alta respectivamente. Si bien difieren en algunas otras variables, esto tiene total sentido, pues ,precisamente, a mayor carga, mayor consumo de aire, gas, y energía.

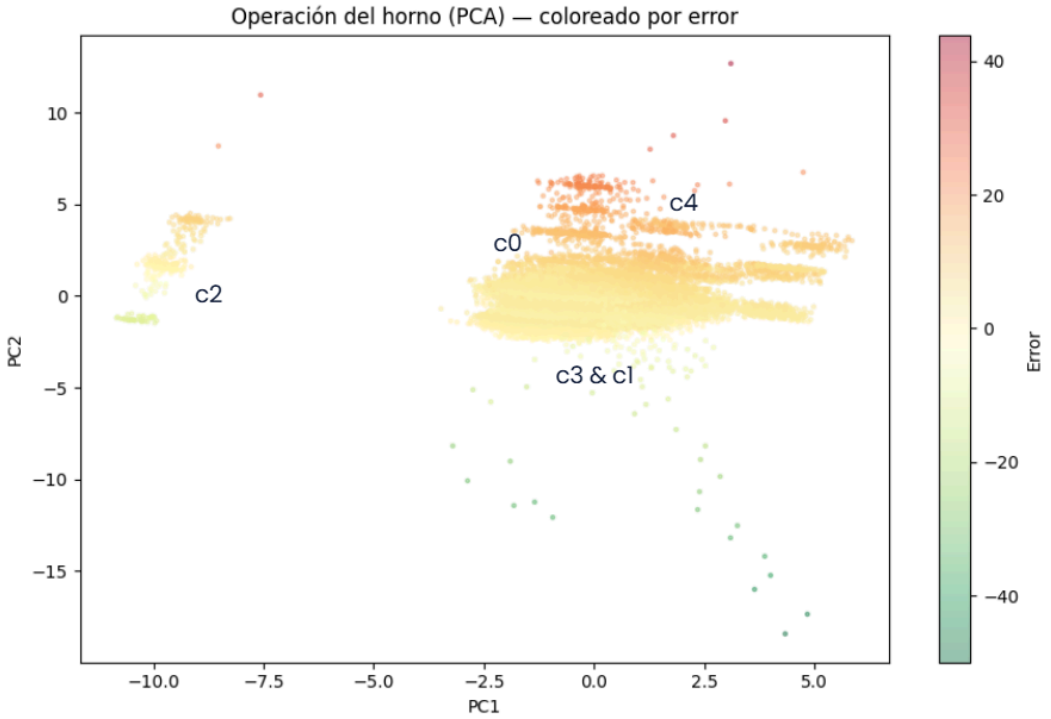
Por otro lado, el cluster 2 habla de muestras en las que ya no es necesario aumentar la temperatura, sino mantenerla. Esto explica el error mínimo, además de los flujos de aire y gas bajos, puesto que este es el punto donde el horno está más estable.

Por último, el cluster 4 es el de mayor error en promedio, y el de mayor temperatura. Este cluster contiene 962, por lo que podría ser el más interesante para ajustar el PID, aunque la existencia de este cluster también podría atribuirse al delay inherente que arrastra un horno fusor.

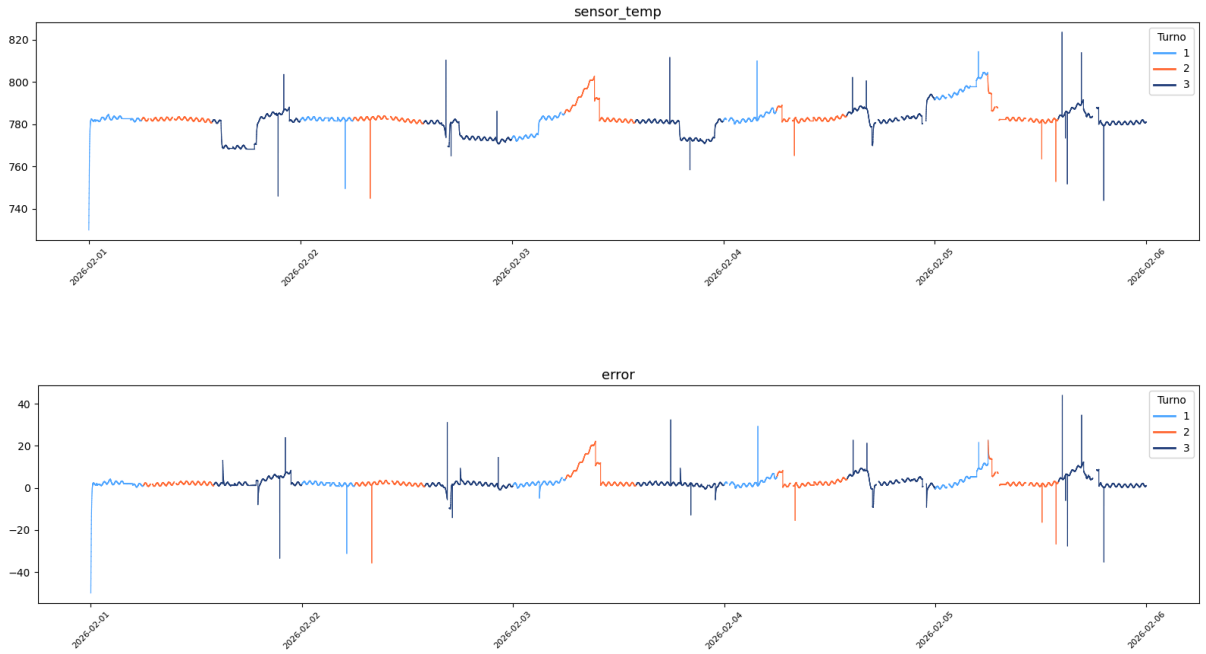
En la siguiente figura se colorea el mismo espacio por error, en lugar de cluster:



Se observa algo muy interesante, que es que las concentraciones de error parecieran tener una agrupación similar a la de los clusters:



Esto indica que sí hay una manera de categorizar a las muestras que es útil para predecir el error. Basado en esa teoría, se crea una línea del tiempo de los datos asignando un color al cluster al que pertenece.



Se observa que el cluster cambia de cierta forma en un patrón, lo que indica que sí hay una relación temporal importante. Con este último hallazgo, se tiene toda la información necesaria para pasar a la siguiente fase del modelo basado en datos.

Las métricas de error utilizadas fueron MAE, RMSE y MAPE, y las variaciones no fueron muy altas pero no deberían ignorarse. La primera métrica de error fue de 1.92° de diferencia, la segunda de 2.82° y la tercera indicó un error en porcentaje del 0.2462%.

A partir del modelo creado con todas las variables, se obtuvieron los pesos de cada uno de los regresores para determinar las variables más significativas y, con un modelo preliminar, determinar cuál utilizar para modelar el sistema. El modelo eligió a air_flow (el flujo de aire) y furnace_load (la carga del horno) como las variables regresoras más significativas.

Selección y justificación del modelo de Deep Learning

Las redes neuronales han demostrado ser útiles para aproximar funciones cuando se tienen suficientes datos para llevar a cabo un entrenamiento adecuado. Esto hace que sean comúnmente utilizadas en sistemas físicos con dinámicas complejas que requieren de precisión. En control, el enfoque clásico parte de una función de transferencia, sin embargo, en la práctica esta no siempre se tiene. En ocasiones, obtener dicho modelo puede resultar muy costoso, requerir de experimentos, y es posible que la función de transferencia para algún proceso cambie de vez en cuando. Así, en este contexto, las redes neuronales ofrecen la posibilidad de aprender el comportamiento del sistema directamente desde los datos de operación.

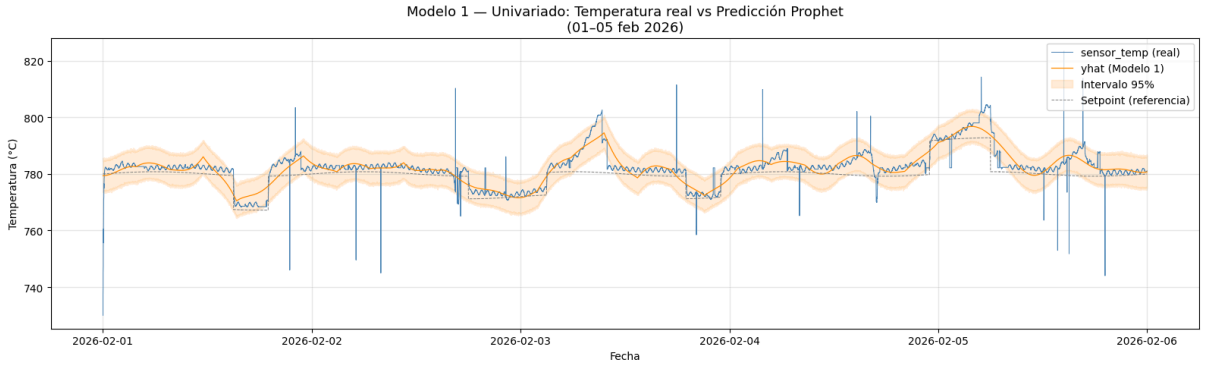
En el caso específico del horno fusor, esto es relevante, pues la dinámica cambia según la carga de aluminio, la temperatura ambiente, y otros factores. Una red neuronal entrenada con datos reales del proceso puede lograr aprender distintas variaciones, para así producir una aproximación del comportamiento del sistema en condiciones reales de operación.

Modelo preliminar

Como primer acercamiento a un modelo que sea capaz de predecir la temperatura y el comportamiento del sistema dados ciertos cambios en el setpoint y perturbaciones existentes en el mismo, se generó un modelo de predicción llamado Prophet, el cual se utiliza para predicción de series de tiempo en un modelo aditivo donde las tendencias no lineales se ajustan ya sea con estacionalidad anual, semanal o diaria. Además, es completamente automático y maneja adecuadamente los outliers, que para el horno significan los cambios de temperatura bruscos o posibles fallas en los sensores. Para modelar la temperatura del horno se utilizó la diaria, ya que se cuentan con datos de varios días, suficientes para capturar el comportamiento del sistema.

Dado que el dataset tiene 732 valores faltantes en la columna de predicción, sensor_temp, para ajustar el modelo y evitar errores se reemplazaron los valores vacíos con la temperatura media, lo cual es lo más adecuado cuando el 3% de la columna es faltante y los datos son numéricos.

Después de la limpieza mínima de datos, el modelo trabajó automáticamente en obtener las temperaturas esperadas del sistema, además de obtener el rango de temperaturas dentro de un 95% de confianza estadística:



Comparando la temperatura predicha con la real, el modelo responde de manera adecuada a los cambios en la referencia (setpoint) y los acerca bastante a la realidad. Los cambios de temperatura bruscos que son de una o pocas muestras, que se pueden deber a errores de lectura o un comportamiento inusual en el horno, el modelo no los toma en cuenta debido a la poca cantidad de muestras que son.

En general, el modelo Prophet puede simular adecuadamente el comportamiento real de un sistema complejo como el horno, aunque para obtener una función de transferencia se requiere un modelo que pueda arrojar resultados que permitan el cálculo de la ganancia, el retardo y la constante de tiempo, no solamente una gráfica de predicción, aunque esto no significa que no sea útil.

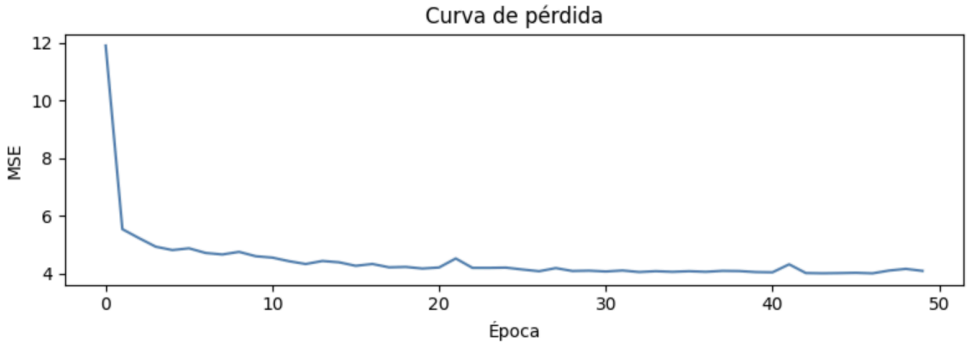
Para obtener los cálculos requeridos ya mencionados para predecir una función de transferencia, se proponen los modelos de Deep Learning mostrados en las siguientes secciones.

Modelo preliminar con Deep Learning

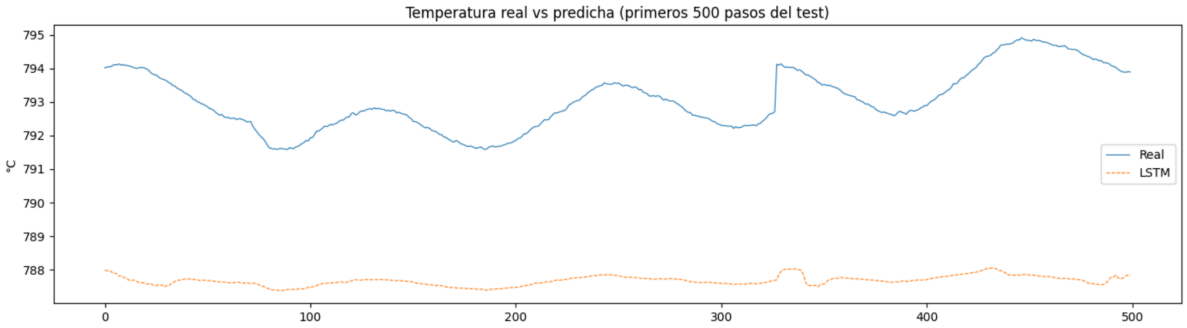
Como primer acercamiento al deep learning, se entrenó una red LSTM (Long Short-Term Memory). Este es un tipo de red neuronal recurrente comúnmente utilizada para series de tiempo, pues posee la capacidad de aprender dependencias temporales, pues el LSTM, como su nombre indica, logra recordar información de pasos anteriores. (Wang, 2026). Por esto mismo, se optó por utilizarlo como modelo preliminar, ya que el horno fusor no sólo presenta retardo, sino que el comportamiento del horno depende de lo que haya sucedido previamente. Asimismo, como fue visible en el EDA anterior, existen diferentes regímenes de operación para el horno, característica que LSTM es capaz de manejar.

El modelo LSTM se entrenó con 20,868 registros tras la eliminación de muestras con NAs y de datos atípicos, pues se buscó evitar incluir datos que pudieran confundir a la red neuronal durante el entrenamiento. Se utilizó una ventana de 15 pasos hacía atrás, es decir, que para la predicción de un nuevo punto punto, se utilizaran los 5 minutos previos como contexto. Asimismo, el dataset se dividió en 80% como set de entrenamiento, y 20% como set de prueba.

La arquitectura, a grandes rasgos consistió de 2 capas entrenadas durante 50 épocas con el optimizador Adam, sin embargo, la pérdida se estabilizó alrededor de la época 30, como es visible en la siguiente figura:

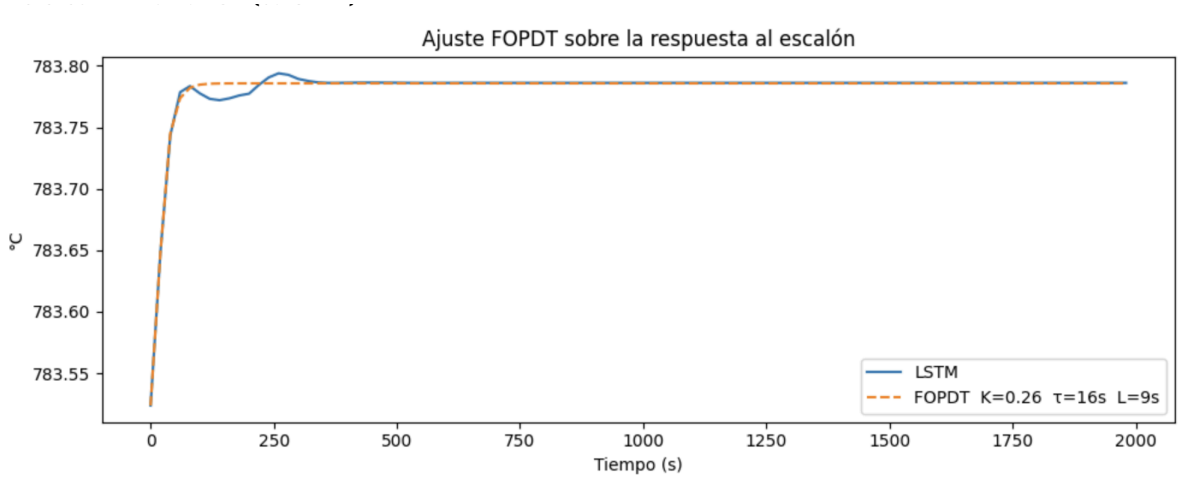


En cuanto a la predicción de temperaturas, este modelo obtuvo un RMSE de 4.84°C y un MAE de 3.01°C. Si bien este error es relativamente pequeño, y estaría dentro del rango permisible para Ronal Group, el resultado dejó en claro que existe margen de mejora quizás cambiando de arquitectura.



Para la obtención de la función de transferencia, se simuló la respuesta del modelo agregando una entrada escalón y se ajustó un modelo FOPDT(First Order Plus Dead

Time), sobre la curva obtenida. Finalmente, se extrajeron los parámetros, obteniendo una ganancia K de 0.26°C, una constante τ de 16.4s y un retardo L de 9.4 segundos.



Es claro que estos valores no son realistas; el retardo llama la atención sobre todo, pues sabemos que no es posible que un horno fusor industrial alcance temperaturas cercanas a los 800°C en menos de 10 segundos. Esto confirma que este modelo de Deep Learning no ha logrado capturar la dinámica del horno fusor, por lo que este modelo únicamente queda como benchmark.

Redes Neuronales Convolucionales

Aunque las redes neuronales convolucionales, o CNNs, fueron desarrolladas para procesamiento de imágenes, también resultan útiles para tareas de este tipo, pues poseen la capacidad de detectar patrones locales en series de tiempo. De esta manera, una red neuronal convolucional puede aprender subidas, bajadas, y oscilaciones. A diferencia de LSTM, CNN es más eficiente computacionalmente, y particularmente buena cuando los patrones son locales y se repiten.

Además de esto, tras el análisis exploratorio de los datos, se encontraron tres hallazgos importantes que respaldan la elección de este modelo de Deep Learning. En primer lugar, se observaron picos de hasta ±50°C, y precisamente este tipo de patrones locales logran ser detectados y aprendidos por la CNN, sin dejar que los picos dominen toda la predicción. Por otro lado, se observó que existe una dinámica relativamente regular entre turnos evidenciado por el comportamiento consistente durante el turno matutino, el vespertino y el nocturno. Como se mencionó anteriormente, las CNN son excelentes cuando los patrones que se deben aprender

se repiten con estructuras similares. Por último, también se encontró que las tres variables más relevantes (‘gas_flow’, ‘air_flow’ y ‘energy_consumption’) tenían correlaciones de Pearson de >0.90, lo cual puede ser fácilmente aprendido por CNNs.

Así fue como se llegó a la decisión de cambiar de método de Deep Learning, pasando de un modelo más costoso computacionalmente como LSTM a CNNs.

Implementación del modelo de Deep Learning

Dentro del contexto de los datos de Ronal Group, CNN también puede ser un método valioso, pues puede aprender a distinguir entre los diferentes tipos de operación. A continuación se presenta el proceso de entrenamiento para posteriormente predecir un grupo de temperaturas, ajustar un modelo FOPDT, y extraer los parámetros necesarios para el diseño del controlador PID. A continuación, se presenta el proceso seguido para el entrenamiento y la implementación de la CNN que permitirá aproximar la función de transferencia, y consecuentemente, modelar el comportamiento del sistema a partir de los datos.

Ingeniería de variables

El dataset original cuenta con nueve variables: timestamp, sensor_temp, setpoint, gas_flow, air_flow, furnace_load, ambient_temp, gas_pressure y energy_consumption.

A partir del análisis exploratorio y de los criterios de selección descritos a continuación, se definió el siguiente conjunto de entradas para el modelo CNN: features = ['sensor_temp', 'gas_flow', 'furnace_load', 'error', 'setpoint']

Variables incluidas:

- sensor_temp: temperatura medida en tiempo real por el sensor del horno. Es la variable de salida del sistema y, al incluirse como entrada, le proporciona al modelo el estado térmico actual como punto de partida para la predicción.
- gas_flow: porcentaje de flujo de gas. Representa la entrada de energía principal al proceso y es el actuador directo sobre la temperatura.
- furnace_load: carga de aluminio en kilogramos. Actúa como perturbación física del sistema; una mayor masa implica mayor inercia térmica y modifica la dinámica de calentamiento.
- error: diferencia entre sensor_temp y setpoint en cada instante. Al incorporar esta variable, el modelo dispone de información directa sobre la desviación respecto al objetivo, lo que mejora de forma medible la precisión de predicción frente a configuraciones en las que dicha desviación permanece implícita.

- setpoint: referencia operacional de temperatura. Se incluye porque no es constante a lo largo del tiempo y presenta variaciones que, según el análisis de los datos, se pueden relacionar con picos de temperatura unas horas después. Su inclusión explícita permite al modelo anticipar el efecto de cambios en la referencia.

Variables descartadas:

- air_flow, energy_consumption: presentan correlación de Pearson superior a 0.90 con gas_flow. Su inclusión no aportaría información independiente al modelo y aumentaría innecesariamente la dimensionalidad de la entrada. Además, estas variables no figuran como regresores en el modelo Prophet utilizado como baseline, lo que permite una comparación metodológica más coherente entre enfoques.
- gas_pressure: variable con baja variabilidad registrada en el dataset y sin presencia en el modelo baseline (prophet).
- ambient temp: variable con baja variabilidad, que aunque sí podría relacionarse al turno de trabajo, al ser una secuencia de tiempo no resulta necesario
- timestamp: dado que la red neuronal ya tratará los datos en orden, no es necesario agregar la fecha ni la hora de las muestras; porque de una forma u otra ya tienen esa información incluida y agregar esta variable sólo introduciría ruido al modelo.

Tratamiento de datos previo al modelado

Se identificaron 732 valores nulos en sensor_temp, correspondientes a fallas puntuales del sensor. Estos valores se imputaron mediante interpolación lineal, método adecuado dado el carácter continuo y suavizado de la dinámica térmica del horno. Adicionalmente, se eliminaron las muestras correspondientes al percentil inferior al 1% y superior al 99% de sensor_temp (433 filas, 2% del total), asociadas a lecturas anómalas de corta duración cuya causa más probable es el ruido instrumental. Tras la limpieza, el dataset de trabajo quedó conformado por 21,167 muestras y 6 variables.

Todas las variables se normalizaron mediante StandardScaler (media cero, varianza unitaria), práctica estándar para redes neuronales que evita que variables de mayor magnitud dominen el aprendizaje.

Construcción de ventanas temporales

El modelo recibe como entrada una ventana deslizante de LOOKBACK = 900 pasos (cinco horas), y predice la temperatura del paso siguiente.

Esta decisión viene de que los datos muestran que movimientos bruscos en el setpoint se manifiestan en la temperatura como picos agresivos aproximadamente 4 horas después, por lo que la ventana debe cubrir ambos eventos. Además, este valor es consistente con la constante de tiempo teórica del sistema (τ = 10,800 s, que son tres horas) derivada del modelado clásico. Por lo que se escoge entrenar a la red con cinco horas de lookback.

El dataset se dividió cronológicamente: 80% para entrenamiento (primeras 16,909 ventanas) y 20% para prueba (últimas 4,228 ventanas), preservando el orden temporal.

Modelo: Arquitectura, Entrenamiento y Validación

Arquitectura

Se implementó una Red Neuronal Convolucional unidimensional (CNN-1D) en PyTorch para la predicción de temperatura del horno fusor. La elección de CNN sobre LSTM responde a que el sistema presenta patrones temporales locales y repetibles entre turnos — picos, subidas y caídas características — que las capas convolucionales detectan eficientemente sin requerir el procesamiento secuencial de las redes recurrentes.

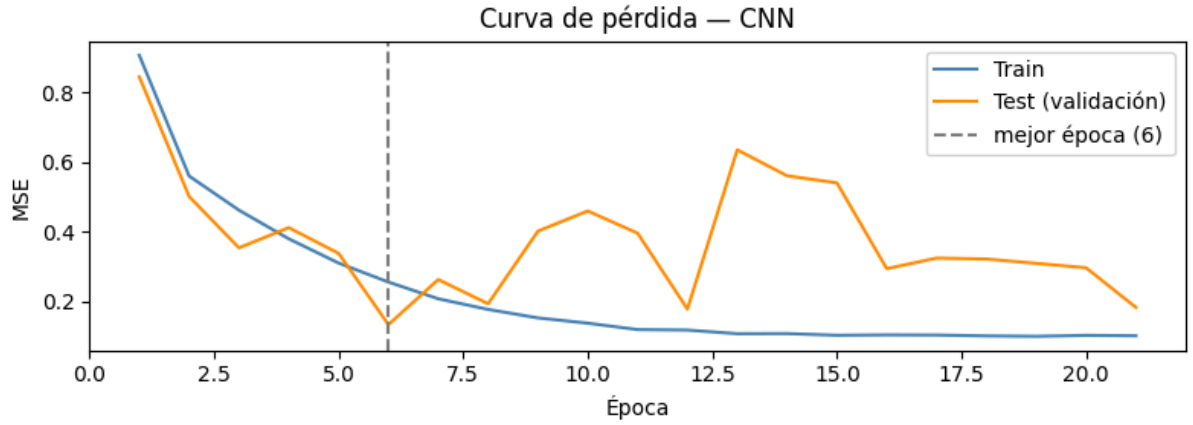
La red se compone de dos bloques:

> **Bloque convolucional:** dos capas Conv1d con kernels de tamaño 3 y padding simétrico (preserva la longitud de la secuencia), activación ReLU, y una capa AvgPool1d con kernel 2 que reduce la dimensión temporal a la mitad. Los mapas de características pasan de 5 canales (variables de entrada) a 64 y luego a 128 filtros, lo que permite al modelo extraer representaciones de complejidad creciente.
>
> **Bloque fully connected:** una capa Flatten seguida de una capa lineal de 57,600 entradas (= 128 filtros × 450 pasos tras el pooling), ReLU, Dropout 0.2, y salida de dimensión 1 (temperatura predicha en el siguiente paso).

Entrenamiento

El modelo se optimizó con Adam (lr = 1×10^{-3}) minimizando el error cuadrático medio (MSE) sobre lotes de 64 muestras, con un máximo de 150 épocas. Se implementó early stopping con paciencia de 15 épocas sobre la pérdida de validación, guardando automáticamente el checkpoint de mejor desempeño (best_cnn.pt). El entrenamiento se realizó sobre las primeras 16,213 ventanas (80% cronológico del dataset).

En la siguiente gráfica se observa la gráfica con la curva de pérdida en esta CNN. Se observa como la mejor época es la número 6.



Esta época tiene un MSE normalizado de 0.2559 en train y de 0.1342 en test.

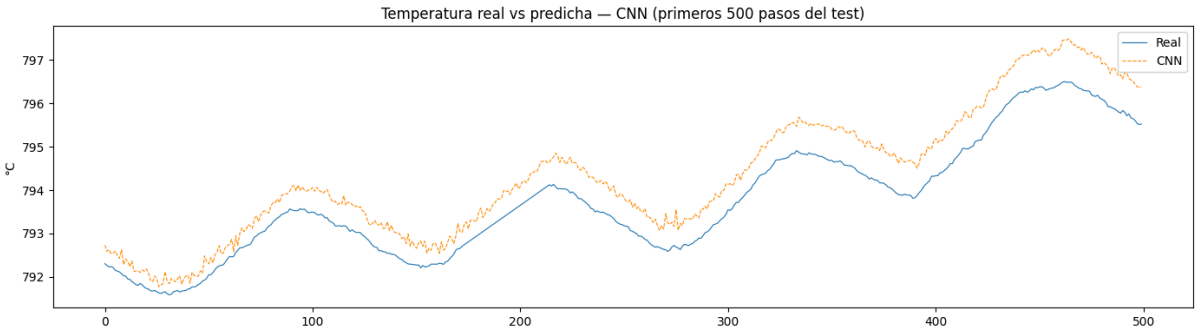
Validación

Los valores finales de las métricas son:

- RMSE: 0.6019 °C
- MAE: 0.4009 °C
- R^2: 0.989272.

El valor de R^2 tan cercano a uno es de esperarse porque la temperatura es relativamente estable.

Se puede observar en la siguiente figura que el modelo reproduce casi perfecto la dinámica de la temperatura de salida. Este modelo identifica correctamente tendencias, picos y valles dentro del conjunto de prueba. Sin embargo, se observa un sesgo positivo sistemático de aproximadamente 1–2°C en la predicción, lo que indica que el modelo sobreestima la temperatura de forma consistente.



Dinámica del sistema

La CNN entrenada es un modelo predictivo que va de punto en punto. Es decir, dada una ventana de los últimos instantes, predice la temperatura del siguiente paso. Sin embargo, para el objetivo de control clásico se necesita tener una función de transferencia que describa la dinámica continua del sistema.

Existen múltiples opciones para lograr esto, en este proyecto se escogió usar FOPDT no solo porque es el método tradicional, sino porque es el que mejor se adaptó a las necesidades. El método consiste en que, sobre la respuesta diferencial se ajusta un modelo FOPDT (First Order Plus Dead Time), que describe un sistema de primer orden con retardo:

$$y(t) = K \cdot \Delta U \cdot \left(1 - e^{-(t-L)/\tau}\right)$$

Con tres parámetros:

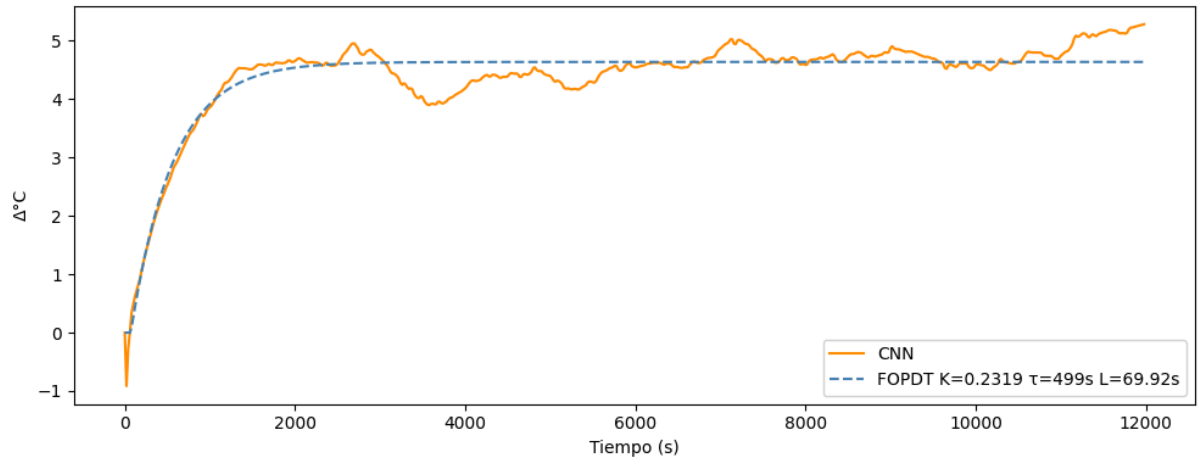
1. Ganancia K: cuánto cambia la temperatura por unidad de cambio en el flujo de gas)
2. Constante de tiempo τ: qué tan rápido responde el horno. Este parámetro, se ajusta con
3. Retardo L: cuánto tarda el sistema en empezar a reaccionar

El primer paso es simular la respuesta del horno ante un incremento súbito de 20 unidades en una variable del sistema. En este caso se eligió al flujo de gas porque se busca aplicar el escalón unitario a la planta; es decir $G = T/U$; para que la función resultante modele el comportamiento en base a las variables propias de la dinámica física del sistema.

Este escalón se aplica de forma encadenada sobre la CNN; en donde cada predicción se pasa como la entrada de la siguiente, lo que genera una respuesta al escalón completo. Sin embargo, esta cadena autorregresiva acumula al error lo que produce un drift. Es decir, aunque la entrada no cambie, la temperatura deriva con el tiempo, únicamente por la acumulación de error de predicción.

Para aislar el efecto real del escalón se corren dos simulaciones idénticas; una sin escalón (drift puro) y una con el escalón aplicado (drift + respuesta real). La diferencia cancela al drift y deja únicamente la respuesta limpia al escalón. Esta señal diferencial "pura" es la que se usa para el ajuste posterior.

Se genera la siguiente figura, en la que es posible comparar visualmente a la función FOPDT con el comportamiento de la CNN.



De aquí también se obtiene τ directamente con un valor de 499 segundos. Dado que representa un valor exageradamente rápido para un horno industrial; de los tres parámetros del ajuste se conservan únicamente K y L. Por su lado, τ se reemplaza por el valor teórico del horno (τ = 10,000 s), derivado del modelado físico clásico.

Esta sustitución constituye la restricción dinámica impuesta al sistema identificado y garantiza que la función resultante describa la dinámica real del horno.

Los parámetros finales son:

- Ganancia K: 0.2319 °C/unidad de gas
- Constante de tiempo τ: 10,000 s ➜ 166.67 min
- Retardo L: 69.92 s ➜ 1.17 min

Aplicando la transformada de Laplace al modelo FOPDT se obtiene la función de transferencia continua:

$$G(s) = \frac{0.232}{10{,}000s + 1} \cdot e^{-69.9s}$$

Dado que el término de retardo e^{-Ls} no es una función racional, no puede expresarse como cociente de polinomios comparable con el modelo de control clásico. Por lo que se aplica la aproximación de Padé de primer orden:

$$e^{-Ls} \approx \frac{1 - \frac{L}{2}s}{1 + \frac{L}{2}s}$$

Al sustituirla en G(s), el denominador queda de segundo orden. Se obtiene la forma racional lista para Simulink:

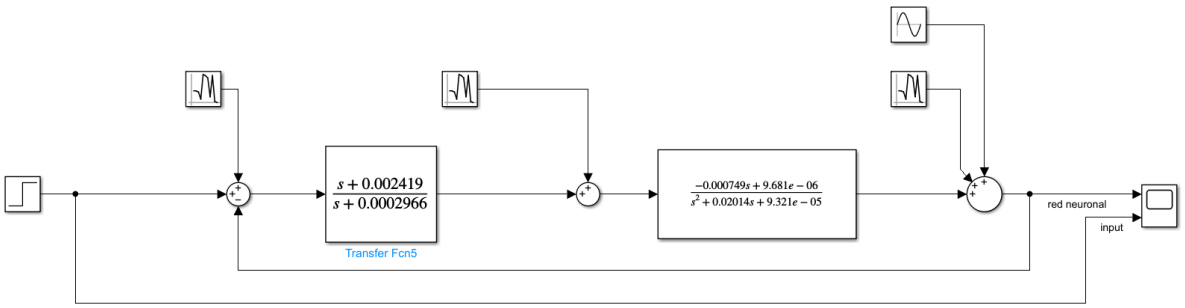
$$G(s) = \frac{-8.107s + 0.232}{349{,}601.18s^2 + 10{,}034.96s + 1.00}$$

Dividiendo numerador y denominador entre el coeficiente de s^2 para la forma polinomial estándar, que facilita la comparación directa con el modelo clásico:

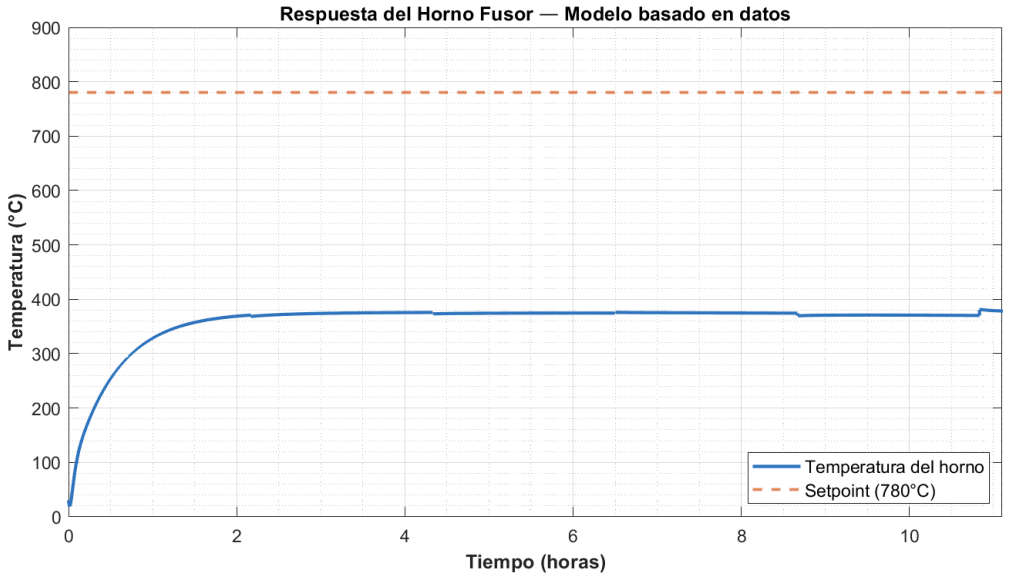
$$G(s) = \frac{-2.319 \times 10^{-5}s + 6.633 \times 10^{-7}}{s^2 + 0.0287s + 2.86 \times 10^{-6}}$$

Implementación del modelo basado en datos en Simulink

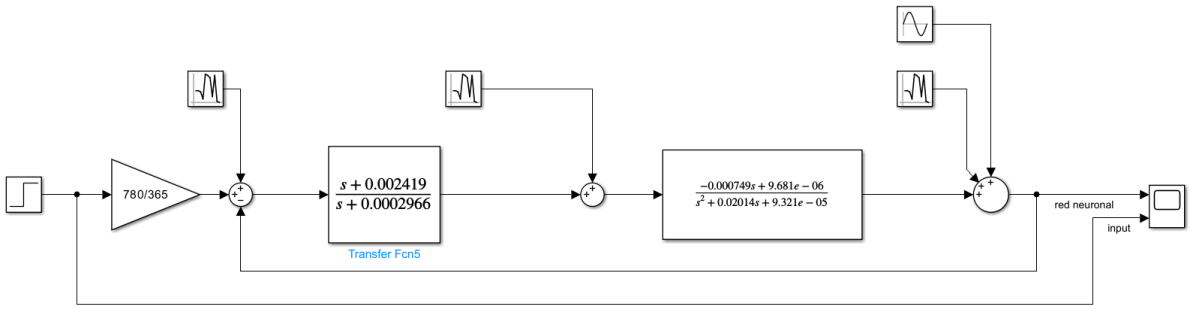
La G(s) en forma estándar se integra en un diagrama de Simulink de la siguiente manera, en dónde pueda representar a la función de transferencia en el horno fusor.

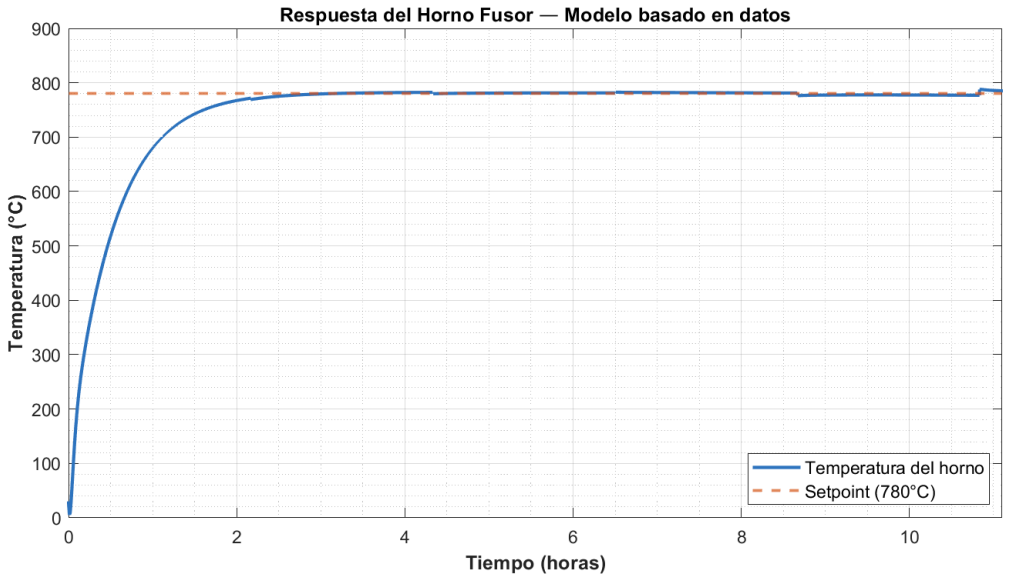


Con la salida:



Al notar que el error en estado estable es significativo, se ajusta con el Teorema del Valor Final, se obtiene lo siguiente:





Cabe mencionar que este modelo no necesita un bloque de saturación pues ese comportamiento ya está dentro de la función de transferencia que fue modelada con restricciones a la dinámica, lo que hace redundante tener un bloque de saturación.

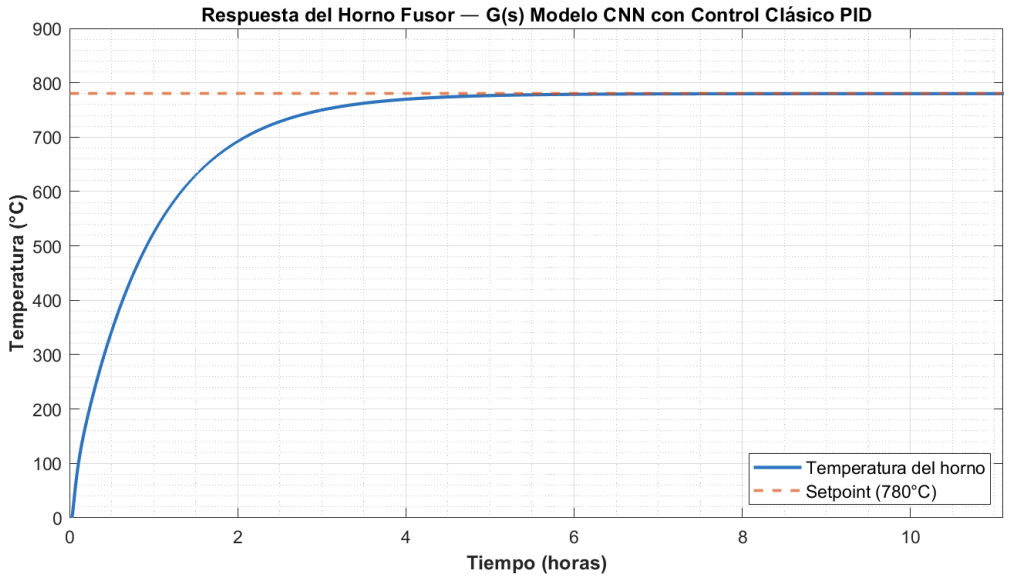
Se obtiene del diagrama de bloques del sistema la ecuación en lazo cerrado del sistema en su forma polinomial (TF)

$$G_{closed}(s) = \frac{-0.0008866s^2 + 9.315 \times 10^{-6}s + 2.772 \times 10^{-8}}{s^3 + 0.02043s^2 + 9.921 \times 10^{-5}s + 2.772 \times 10^{-8}}$$

O bien, en su forma ceros-polos-ganancia (ZPK)

$$G_{closed}(s) = \frac{-0.00088662(s - 0.01293)(s + 0.002419)}{(s + 0.01292)(s + 0.007213)(s + 0.0002974)}$$

La respuesta de esta función a un step replica el comportamiento tal cual, a excepción de las perturbaciones.



Los polos del sistema en lazo cerrado

Real, rápido $p_1 = -0.0129$

Real, intermedio $p_2 = -0.0072$

Real, dominante $p_3 = -0.0003$

Y los ceros del sistema

$z_1 = +0.01293$ este es un cero en el semiplano derecho, fase no mínima

$z_2 = -0.002419$

Análisis de estado estable

$K_{ref} = 369.09$

$K_{DC} = \lim_{s \to 0} G_{closed}(s) = 1.000000$

$T_{ss} = 780 \cdot K_{DC} = 780.00,^\circ C$

$e_{ss} = 780 - T_{ss} = 0.00,^\circ C$

Comparativa

Se comparan ambos métodos con el objetivo de evaluar cuánto puede aportar la incorporación de Deep Learning al proceso de modelado del horno fusor. Se busca demostrar si la aproximación generada a partir del uso de redes neuronales y basado en datos históricos es igual de confiable y produce resultados con un buen desempeño, como los métodos de control clásico y viceversa.

Comparativa de polos y ceros

La comparación de polos y ceros permite entender por qué ambos modelos presentan comportamientos diferentes aunque los dos representen el mismo horno fusor. Se puede observar que ambos sistemas son estables, ya que sus polos se encuentran en el semiplano izquierdo del plano complejo. Esto significa que, ante una entrada de referencia, la respuesta no crece indefinidamente, sino que tiende a estabilizarse con el paso del tiempo.

En el caso del modelo clásico, la ecuación en lazo cerrado del sistema en su forma polinomial (TF) del modelo basado en la teoría de control es:

$$G_{closed}(s) = \frac{-8.407 \times 10^{-5} s^2 + 7.687 \times 10^{-8} s + 6.779 \times 10^{-10}}{s^3 + 0.00365 s^2 + 1.391 \times 10^{-6} s + 6.782 \times 10^{-10}}$$

Presenta un polo real y un par complejo conjugado. La presencia de este par complejo explica que la respuesta tenga un comportamiento subamortiguado, es decir, que la temperatura no llega al setpoint directamente, sino que hay un sobreimpulso y oscilaciones antes de asentarse. Esto coincide con la respuesta observada en la simulación, donde el sistema rebasa la temperatura de referencia y después comienza a corregirse hasta acercarse al valor deseado.

Por otro lado, la ecuación en lazo cerrado del sistema en su forma polinomial (TF) del modelo basado en datos mediante CNN es:

$$G_{closed}(s) = \frac{-0.0008866 s^2 + 9.315 \times 10^{-6} s + 2.772 \times 10^{-8}}{s^3 + 0.02043 s^2 + 9.921 \times 10^{-5} s + 2.772 \times 10^{-8}}$$

Presenta tres polos reales. Al no tener polos complejos, su respuesta es más suave y no presenta oscilaciones marcadas. Esto indica un comportamiento

sobreamortiguado, donde el sistema se acerca al setpoint de forma más lenta, pero más estable. En términos prácticos, el modelo CNN reacciona de manera menos agresiva que el modelo clásico, lo cual puede ser útil para evitar sobreimpulsos fuertes en un proceso térmico como el del horno fusor.

También se observa que ambos modelos tienen un cero en el semiplano derecho: el modelo clásico presenta un cero positivo cercano a +0.0033, mientras que el modelo CNN presenta un cero positivo cercano a +0.0129. Este tipo de cero indica un comportamiento de fase no mínima, lo que significa que el sistema tiene una limitación importante: no puede controlarse de manera demasiado agresiva sin generar respuestas no deseadas. Esto significa que al intentar calentar un horno demasiado rápido, se pueden provocar sobreimpulsos, variaciones térmicas o mayor consumo de energía.

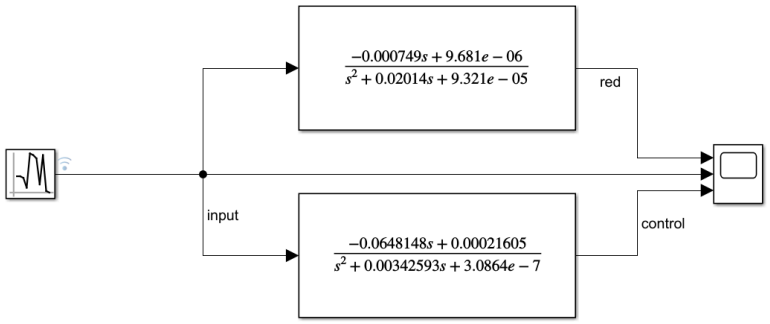
Una diferencia importante aparece en la ganancia de referencia necesaria. El modelo clásico requiere una ganancia aproximada de 1.15, mientras que el modelo CNN requiere una ganancia mucho mayor, cercana a 369. Esto no significa que físicamente el horno necesite una acción de control 369 veces mayor, sino que la función obtenida a partir de datos quedó en una escala diferente a la del modelo clásico. Por esta razón, la comparación no debe hacerse únicamente con las ganancias, sino también con la forma de la respuesta, los polos, los ceros y el tiempo de asentamiento.

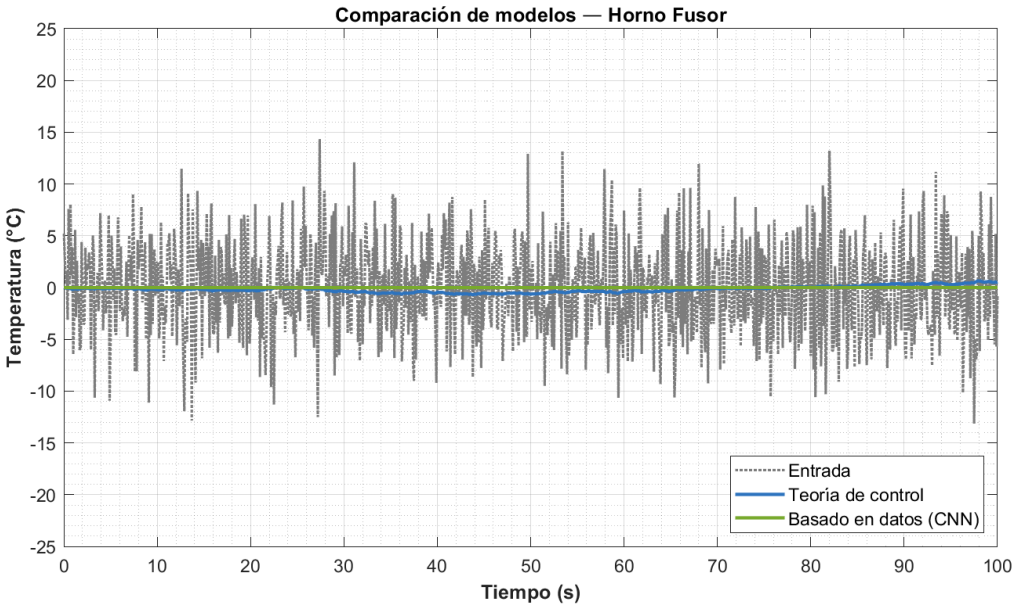
En conclusión, el modelo clásico representa una dinámica más rápida, pero también más oscilatoria, por lo que permite analizar claramente el sobreimpulso y el amortiguamiento del sistema. En cambio, el modelo CNN representa una dinámica más conservadora y suave, con menor tendencia a oscilar, pero con una respuesta más lenta. Por lo tanto, ambos modelos son útiles para analizar el horno fusor, aunque describen su comportamiento desde enfoques distintos: el modelo clásico desde la teoría de control y el modelo CNN desde los datos históricos del proceso.

Comparativa por la respuesta a la misma entrada

En esta sección se compara la respuesta de ambos métodos a una misma entrada, para ver sus diferencias y similitudes; con el fin de que la conclusión de la comparación está también fundamentada desde un punto de vista empírico.

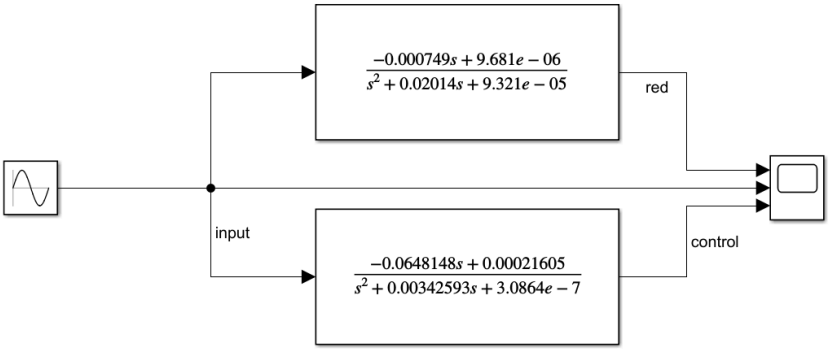
Primero, ante una secuencia de entrada aleatoria.

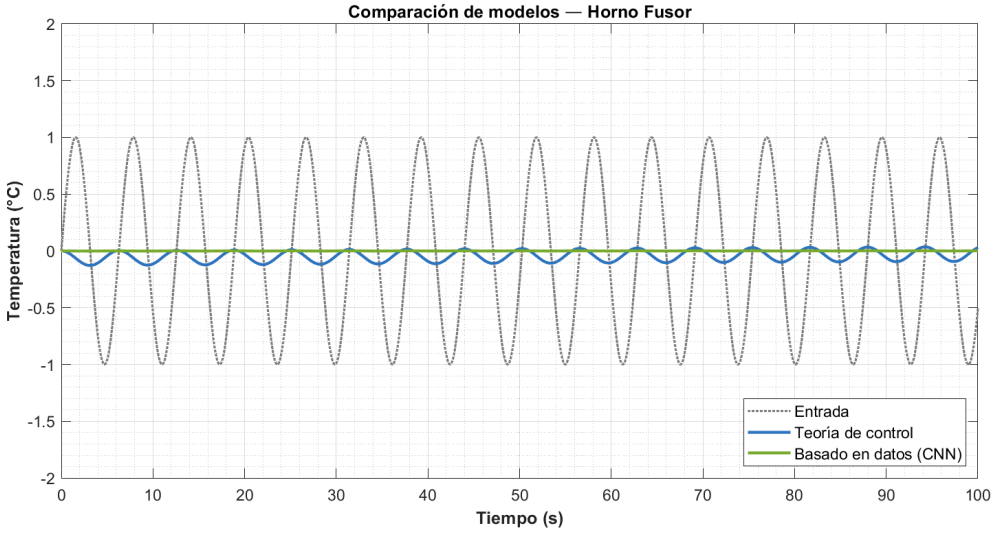


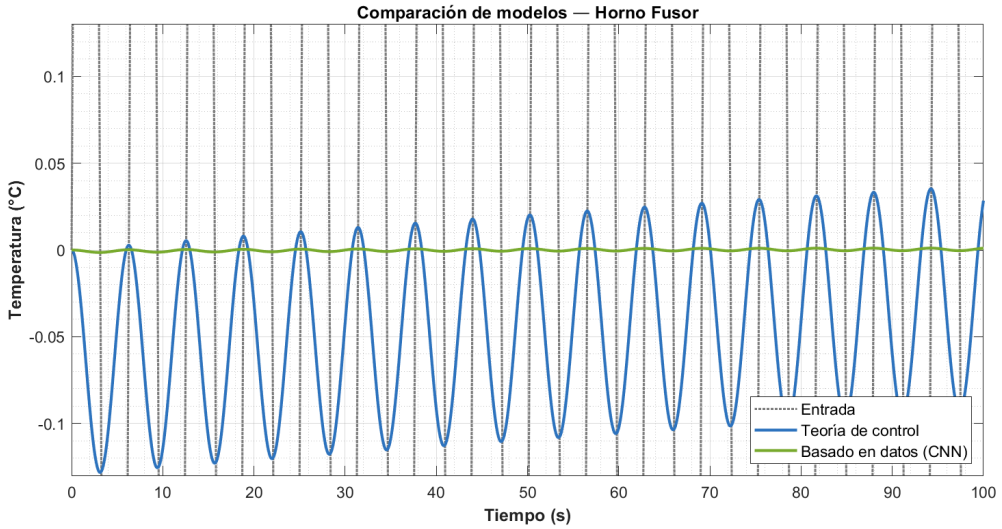


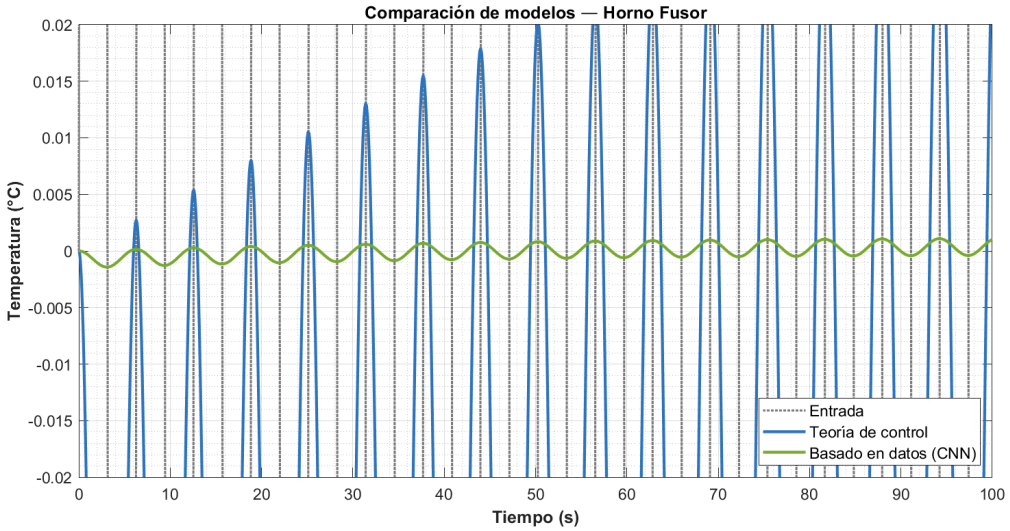
Se observan ligeras diferencias en la manera en la que ambos modelos reaccionan ante esta entrada tan caótica; pero nada realmente interpretable aún.

La segunda comparativa se hace con una entrada senoidal.




Comparación de modelos — Horno Fusor
Temperatura (°C)
Tiempo (s)
Entrada
Teoría de control
Basado en datos (CNN)

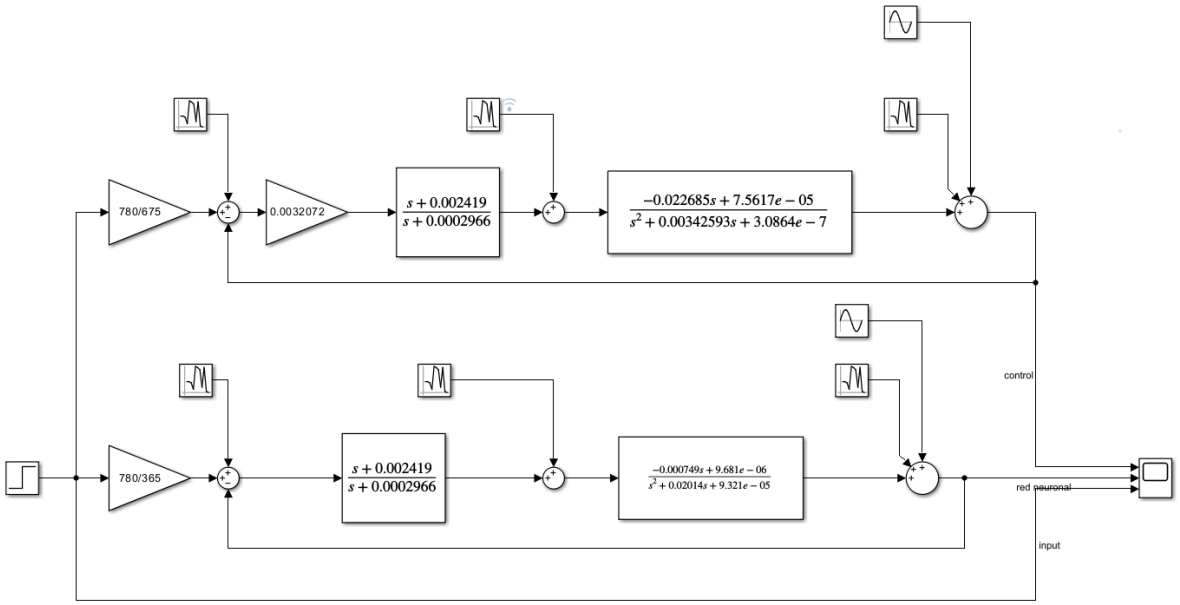

Comparación de modelos — Horno Fusor
Temperatura (°C)
Tiempo (s)
Entrada
Teoría de control
Basado en datos (CNN)


Comparación de modelos — Horno Fusor
Temperatura (°C)
Tiempo (s)
Entrada
Teoría de control
Basado en datos (CNN)

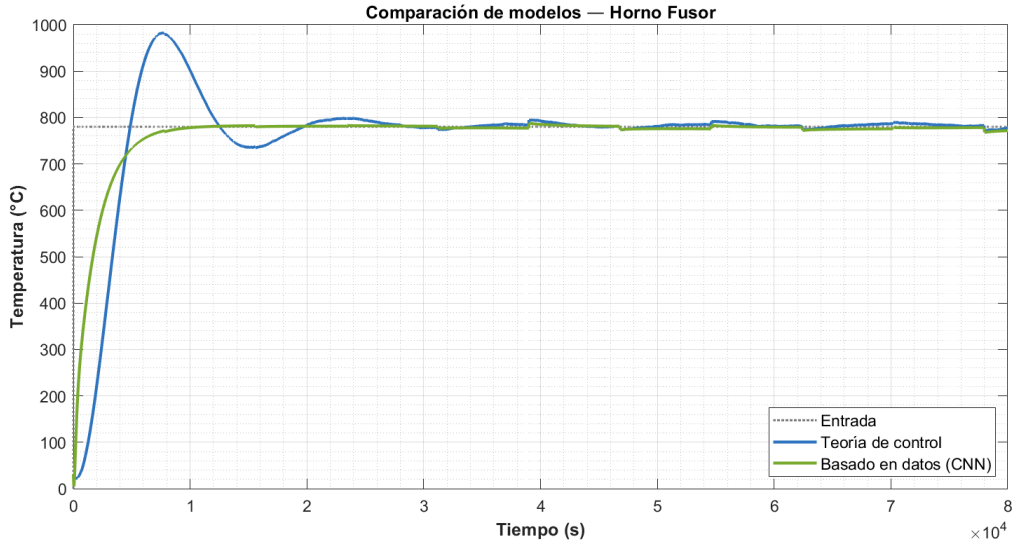
Se observa como ambos modelos replican el comportamiento, pero el modelo basado en la teoría de control responde con una salida de mayor magnitud comparada a la salida del modelo basado en datos. Esto se interpreta como que el modelo basado en datos podría estar sobreamortiguado y por ende no puede reaccionar tanto como el modelo de control.

Comparativa del sistema

Ahora, se busca comparar la dinámica de ambos sistemas. Para facilitar dicha comparativa, se genera el siguiente diagrama. Cabe mencionar que esto sería casi equivalente a comparar las funciones en lazo cerrado, pero aquí sí se incluyen perturbaciones.



A partir de la simulación se obtiene la siguiente respuesta comparativa, en la cual se observan claramente las diferencias dinámicas entre el modelo clásico de control y el modelo basado en datos mediante CNN.



Entre esas diferencias se observa que el modelo de teoría de control presenta una respuesta mucho más agresiva al inicio. La temperatura sube rápidamente, rebasa de forma considerable la referencia de 780°C y después comienza a corregirse mediante oscilaciones hasta acercarse al valor deseado. Este comportamiento indica que el modelo clásico tiene una dinámica más rápida, pero también más sensible al sobreimpulso, lo cual puede ser peligroso en un horno fusor, ya que una temperatura demasiado alta puede generar consumo energético innecesario o afectar las condiciones térmicas del aluminio.

Por otro lado, el modelo basado en datos mediante CNN muestra una respuesta más suave y estable. Aunque también se aproxima al setpoint, lo hace sin presentar un sobreimpulso tan marcado como el modelo clásico. Esto confirma que la CNN representa una dinámica más conservadora, donde la temperatura cambia de manera más gradual. Este comportamiento tiene sentido porque el modelo fue entrenado con datos históricos del proceso y aprende patrones reales del horno, como subidas, bajadas y variaciones locales de temperatura.

También se puede observar que, después de la primera subida de temperatura, ambos modelos terminan trabajando alrededor de la misma zona de operación. Esto es importante porque indica que los dos enfoques logran representar la tendencia general del horno hacia la temperatura de referencia. Sin embargo, la diferencia principal está en la forma en que llegan a ese punto: el modelo clásico llega más rápido, pero con mayor sobreimpulso y oscilación; mientras que el modelo CNN llega de forma más controlada, con menor variación brusca.

En términos prácticos, esta comparación muestra que el modelo clásico es útil para analizar la dinámica teórica del sistema, identificar polos, ceros, estabilidad y comportamiento ante una entrada. En cambio, el modelo CNN resulta útil para

representar el comportamiento del horno desde los datos reales, capturando una respuesta más parecida a la operación cotidiana. Por esta razón, ambos modelos se complementan: el enfoque clásico ayuda a entender matemáticamente el sistema, mientras que el enfoque basado en datos ayuda a aproximar su comportamiento real bajo condiciones de operación.

Discusión de resultados

A partir de las simulaciones y el trabajo realizado, la comparación entre ambos acercamientos demuestra que no existe como tal un enfoque superior, pues tanto las técnicas de control clásico como los modelos de Deep Learning e Inteligencia Artificial, poseen ventajas dependiendo del objetivo que se busque dentro del sistema del horno fusor.

En primer lugar, el modelo clásico resulta conveniente cuando se necesita analizar el sistema basándose en matemáticas. Al obtener una función de transferencia, estudiar polos, ceros, estabilidad, sobreimpulsos y comportamientos dinámicos se vuelve posible; esto, a su vez, lo hace sumamente útil para el diseño de un controlador PID y para la sintonización de sus parámetros, ya que permite comprender la respuesta del sistema ante referencias, entradas, y perturbaciones. Además, presenta una respuesta más rápida, lo que puede favorecer que el horno alcance la temperatura deseada en menor tiempo.

No obstante, esta rapidez también puede representar una desventaja. Esto se debe a que, en las gráficas obtenidas, se observa que el modelo clásico presenta un sobreimpulso mayor, además de oscilaciones antes de estabilizarse por completo. En un proceso industrial como lo es la fundición de metales, esto puede conllevar riesgos, ya que una temperatura superior al valor de referencia trae consigo un mayor consumo de energía, variaciones térmicas, y afectaciones en las condiciones y en la calidad del material.

Por otro lado, el modelo basado en datos mediante redes neuronales convolucionales, mostró un comportamiento más suave y estable. La principal ventaja de este enfoque es que puede aprender a capturar patrones de comportamiento del horno, como cambios en la carga de aluminio, el flujo de gas, la temperatura, diferentes perturbaciones, etc. En comparación, la CNN no presentó un sobreimpulso tan pronunciado, por lo que el acercamiento con Deep Learning puede ser más conveniente si se busca una respuesta menos brusca.

Esto no significa que el modelo con redes neuronales no tenga limitaciones, pues aunque representa mejor ciertos patrones del proceso, este método pierde un poco de la interpretabilidad que posee el control clásico. Además, una aclaración importante es que su desempeño depende fuertemente de la calidad y cantidad de los datos que se utilicen durante su entrenamiento; si los datos no son buenos, la predicción puede volverse poco confiable.

En resumen, el modelo clásico no debe descartarse por completo, incluso cuando en el día a día surgen nuevas tecnologías, pues permite justificar el diseño de un controlador PID. Por otro lado, tampoco vale la pena resistirse a utilizar modelos como las CNNs que son muy útiles para representar el comportamiento del horno a partir de datos reales. Por ello, ambos enfoques deberían utilizarse de manera complementaria.

Conclusión

En conclusión, a lo largo de la elaboración de este proyecto, se logró desarrollar un trabajo que integra control clásico, control moderno, e inteligencia artificial aplicado a un proceso industrial real que forma parte de las operaciones de Ronal Group y que conlleva la fundición de aluminio.

A través del EDA, se logró encontrar las características del comportamiento de los hornos fusores de Ronal Group, identificando con éxito regímenes de operación y las relaciones que existen entre las variables del dataset proporcionado por Ronal Group. Este paso fue esencial para la toma de decisiones informadas sobre qué arquitectura de deep learning sería la más adecuada, resultando en la elección de una CNN que logró modelar la dinámica del sistema con un error considerablemente menor que el modelo preliminar de LSTM. A partir de este modelo, se pudieron extraer los parámetros K, τ, y L de un sistema de primer orden con retardo.

Con esto, se logra el impacto esperado, pues se logró demostrar la utilidad de modelos de Deep Learning para llevar a cabo tareas que antes eran sólo posibles mediante técnicas de control. Además, el uso de Deep Learning demostró ser útil para conocer parámetros esenciales para diseñar un PID que permite estabilizar procesos físicos.

Dentro de este contexto, por ejemplo, el hecho de conocer los distintos regímenes de operación de Ronal Group abre la posibilidad de usar estrategias de control que mejoren la consistencia de sus procesos industriales, incluso cuando las condiciones de los mismos pueden variar. Todas estas mejoras en conjunto garantizan la calidad de los rines de Ronal Group.

Finalmente, este proyecto, al usar redes neuronales para extraer modelos interpretables, crea un precedente para que Ronal Group explore modelos que combinen los métodos tradicionales y los modelos de vanguardia para garantizar resultados a la altura de la empresa.

Anexos y Referencias

Anexos

Repositorio de github

Referencias

1. Franklin, G., et al. (2020). *Feedback Control of Dynamic Systems.* NY, USA: Pearson.
2. Lindberg/MPH. (2026). *Stack (Tower) Melter.* Recuperado de: https://www.lindbergmph.com/products/non-ferrous-melting-and-holding-furnaces/aluminum-melting-and-holding-furnaces/stack-tower-melter/
3. Ogata, K. (2010). *Ingeniería de Control Moderna.* Madrid: Pearson Educación S.A.
4. Ronal Group. (2024). *Historia.* Recuperado de: https://www.ronalgroup.com/es/historia/
5. Smith, G. M. (2024). *¿Qué es un controlador PID?* DeweSOFT. Recuperado de: https://dewesoft.com/es/blog/que-es-un-controlador-pid
6. Uspensky, J. V. (2005). *Teoría de Ecuaciones / Theory of Equations,* México: Editorial Limusa S.A. de C.V.
7. Wang, J. (2026). *Introducción a la memoria a Corto-Largo Plazo (LSTM).* MathWorks. Recuperado de: https://la.mathworks.com/discovery/lstm.html
8. Zill, D. (2009). *Ecuaciones diferenciales con aplicaciones de modelado.* México: Brooks & Cole Cengage.